INFRARED THERMOGRAPHY

Studio di un dataset di termografia con IRT e correzione dei valori registrati attraverso modelli di ML

AGENDA

1. INTRODUZIONE e IDEA
2. DESCRIZIONE DEL DATASET
3. EDA
4. MODELLI
5. RISULTATI
6. CONCLUSIONI

1. INTRODUZIONE E IDEA

La **pandemia** ha portato alla diffusione dei sensori per la misura della temperatura a infrarossi (***IRT***). Essi permettono a differenza dei termometri classici uno screening di massa molto veloce.
Tuttavia impreciso!

L'IDEA: sviluppare e confrontare dei modelli di ML che possano ***correggere gli errori di misurazione***, avendo come *riferimento la temperatura misurata con termometro classico in sito orale.*

1. INTRODUZIONE E IDEA

La misura della temperatura spesso ha:

- un **sito di misura** (dove il termometro effettua la misura)
- un **sito di riferimento** (sito di cui si stima la temperatura, la temperatura in output fornita dal sensore è riferita a questo sito).

Con la termocamera (IRT) è **misurata la temperatura della pelle**, che viene **riferita alla temperatura della cavità orale** (come nel dataset usato) .

Questa “conversione” dalla misura al sito di riferimento può risultare **non accurata** per molteplici **fattori**:

- meccanismo di termoregolazione del corpo umano estremamente complesso,
- colore ed etnia del soggetto
- condizioni della pelle
- fattori ambientali

2. DATASET

PAPER:

"Infrared Thermography for Measuring Elevated Body Temperature: Clinical Accuracy, Calibration, and Evaluation"

STRUMENTAZIONE:

1. TERMOMETRO ORALE
2. IRT
3. WEBCAM
4. BLACKBODY

PROCEDURA:

Prima della misura i soggetti sono stati:

1. fatti acclimatare nell'ambiente condizionato per almeno 15 minuti;
2. posti a una distanza compresa tra 0.6 m e 0.8 m dal sistema webcam-IRT.

È stata, quindi, misurata la temperatura sia con il sistema IRT sia con il termometro orale.

2. DATASET - FEATURES

PAZIENTE

1. **Age** (in fasce discretizzate)
2. **Gender**
3. **Ethnicity**
4. Le temperature, tutte registrate in gradi celsius, sono così divise:

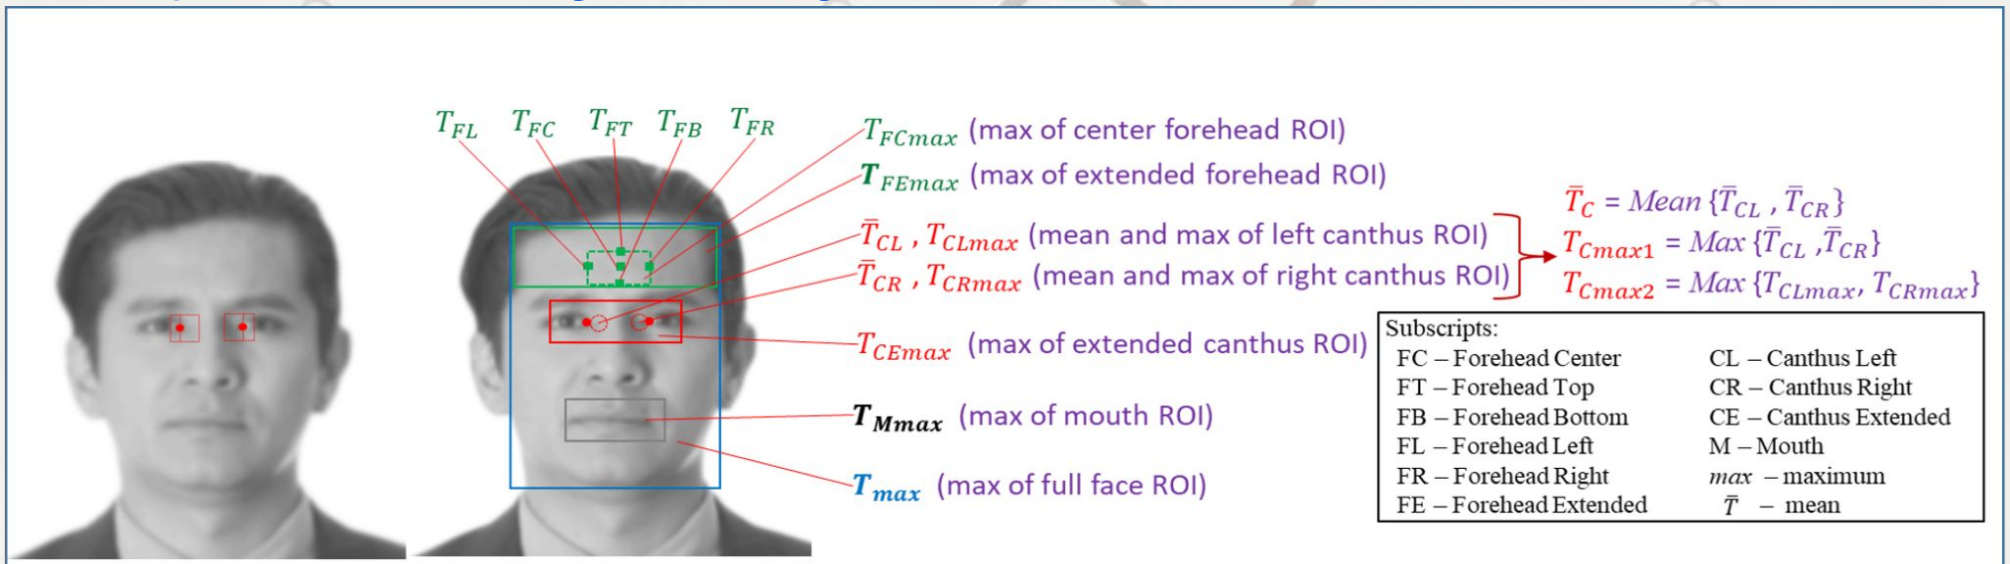


Figure 1. Delineated facial regions and critical points on thermal images: forehead regions and points (green), canthi region and points (red), mouth region (gray rectangle), and entire face (blue rectangle).
Note: The above image is a generic face (based on PowerPoint clip art: Insert > Icons > Cutout People >Alfredo) used for illustration purposes and not an actual participant in our study.

2. DATASET - FEATURES

AMBIENTALI

1. **T_offset1**: offset tra temperatura registrata del blackbody e temperatura reale
2. **T_atm**: temperatura dell'ambiente in cui è stata effettuata la misura
3. **Humidity**: percentuale di umidità dell'ambiente in cui è stata effettuata la misura
4. **Distance**: distanza tra soggetto e IRT

2. DATASET

LABEL

Nell’esperimento la temperatura orale è stata registrata in modalità “fast” e “monitor”, a seconda del tempo più o meno lungo della misura stessa.
È stata scelta come temperatura target il valore misurato con esposizione più lunga perché più accurato.

	aveOralF	aveOralM
count	1020.000000	1020.000000
mean	36.979216	37.028382
std	0.386403	0.509502
min	35.750000	35.540000
25%	36.800000	36.777500
50%	36.900000	36.940000
75%	37.100000	37.140000
max	39.600000	40.340000

3. EDA

- FILTRAGGIO DEI SAMPLE CON FEATURE AVENTI DATI MANCANTI → ELIMINATE

- CONTROLLO DEI VALORI SPERIMENTALI CON min e max →
  Il predittore **Distance** è stato eliminato, perché nell'esperimento la distanza è stata mantenuta nell'intervallo [0.5;0.9], affinché non influenzasse le misurazioni. Si riferisce che un sample riportasse un errore di registrazione della distanza.

- È STATO CREATO IL DATASET GESTENDO LE FEATURE CATEGORICHE

	Distance
count	1018.000000
mean	0.729784
std	2.456486
min	0.540000
25%	0.600000
50%	0.620000
75%	0.700000
max	79.000000

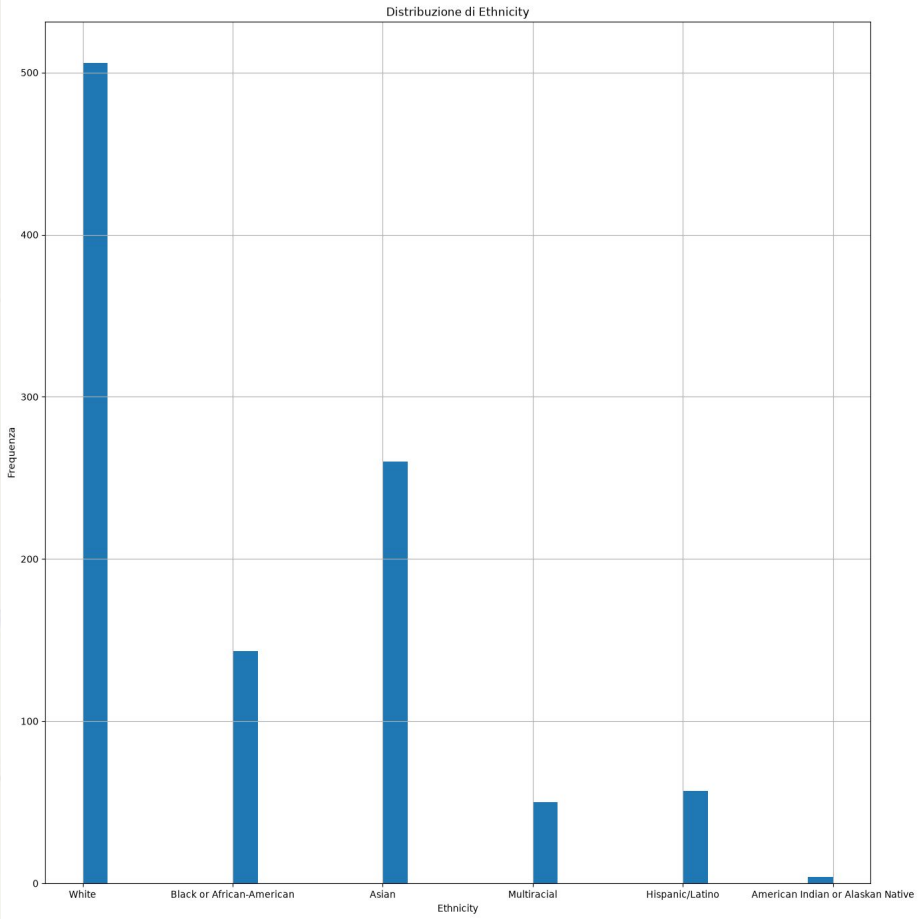


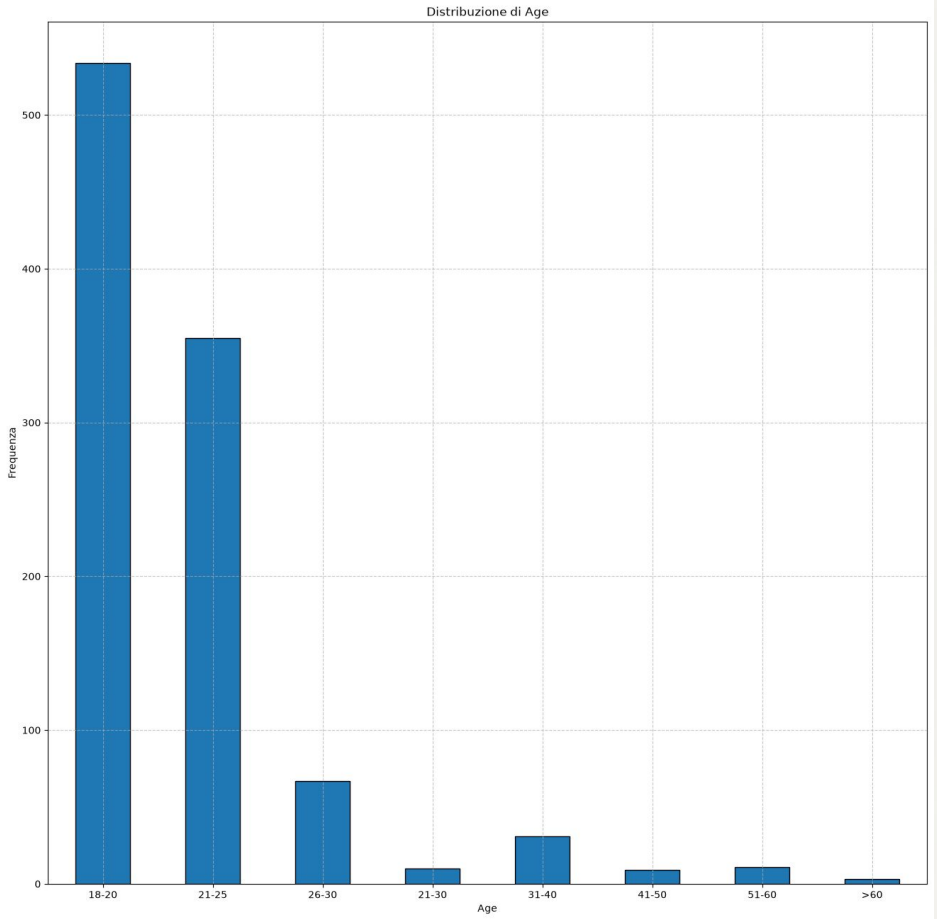
	Distance
count	1015.000000
mean	0.652315
std	0.066794
min	0.540000
25%	0.600000
50%	0.620000
75%	0.700000
max	0.850000

```
<class 'pandas.DataFrame'>
RangeIndex: 1015 entries, 0 to 1014
Data columns (total 37 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   Fascia_Eta              1015 non-null   float64
 1   Asian                   1015 non-null   float64
 2   Black/African_American  1015 non-null   float64
 3   Hispanic/Latino         1015 non-null   float64
 4   Multiracial             1015 non-null   float64
 5   White                   1015 non-null   float64
 6   T_atm                   1015 non-null   float64
 7   Humidity                1015 non-null   float64
 8   Distance                1015 non-null   float64
 9   T_offset1               1015 non-null   float64
 10  Max1R13_1               1015 non-null   float64
 11  Max1L13_1               1015 non-null   float64
 12  aveAllR13_1             1015 non-null   float64
 13  aveAllL13_1             1015 non-null   float64
 14  T_RC1                   1015 non-null   float64
 15  T_RC_Dry1               1015 non-null   float64
 16  T_RC_Wet1               1015 non-null   float64
 17  T_RC_Max1               1015 non-null   float64
 18  T_LC1                   1015 non-null   float64
 19  T_LC_Dry1               1015 non-null   float64
...
 35  T_OR_Max1               1015 non-null   float64
 36  aveOralM                1015 non-null   float64
dtypes: float64(37)
memory usage: 293.5 KB
```

3. EDA

- VISUALIZZAZIONE POPOLAZIONE (divisa in bin) CON ISTOGRAMMI → **SBILANCIAMENTO CLASSI**



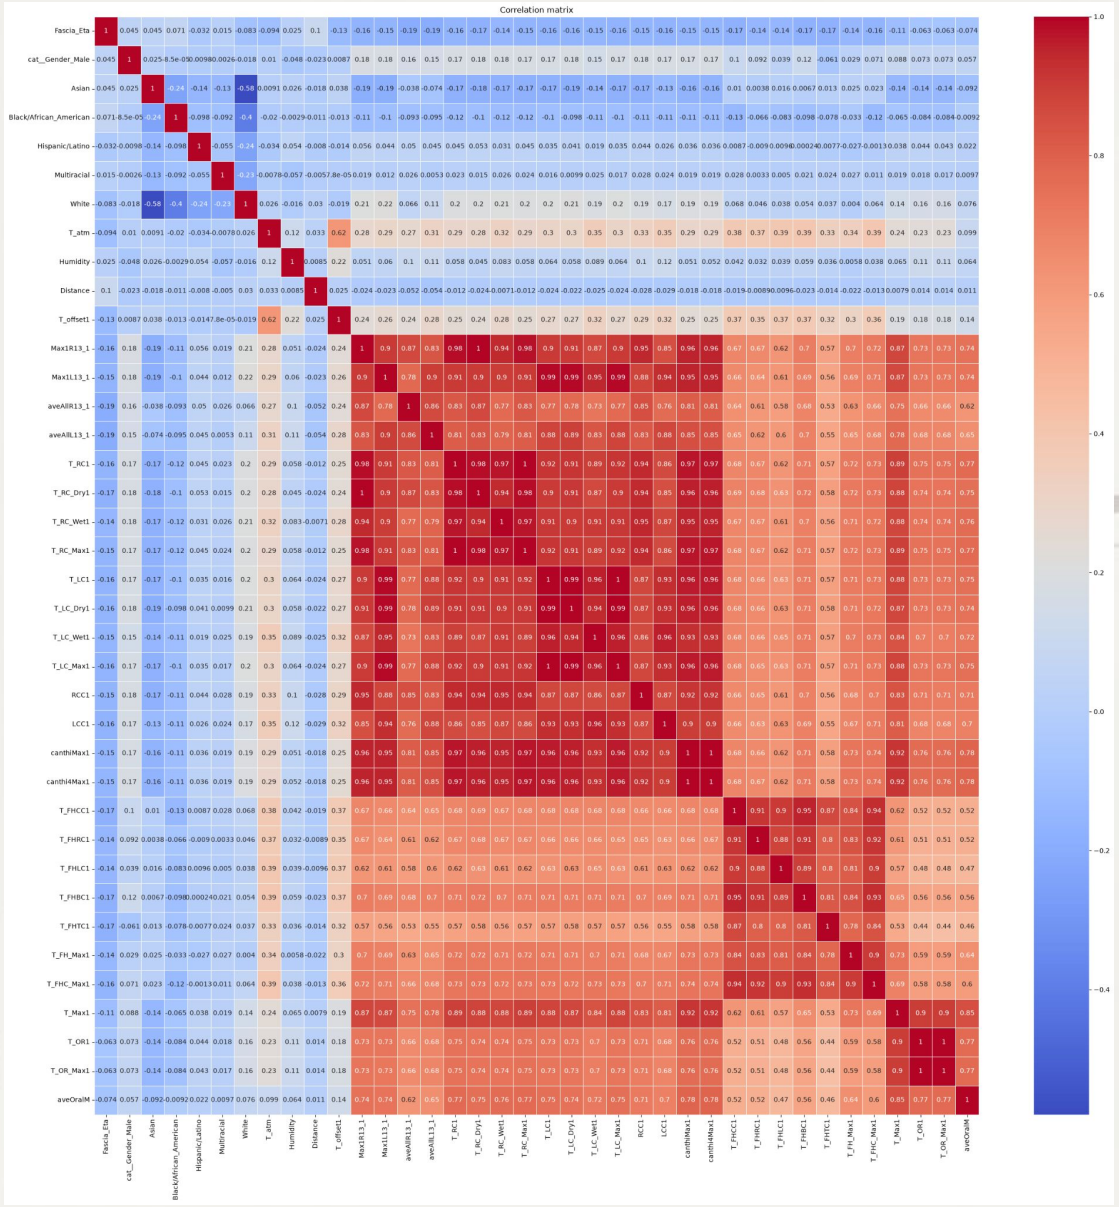


3. EDA

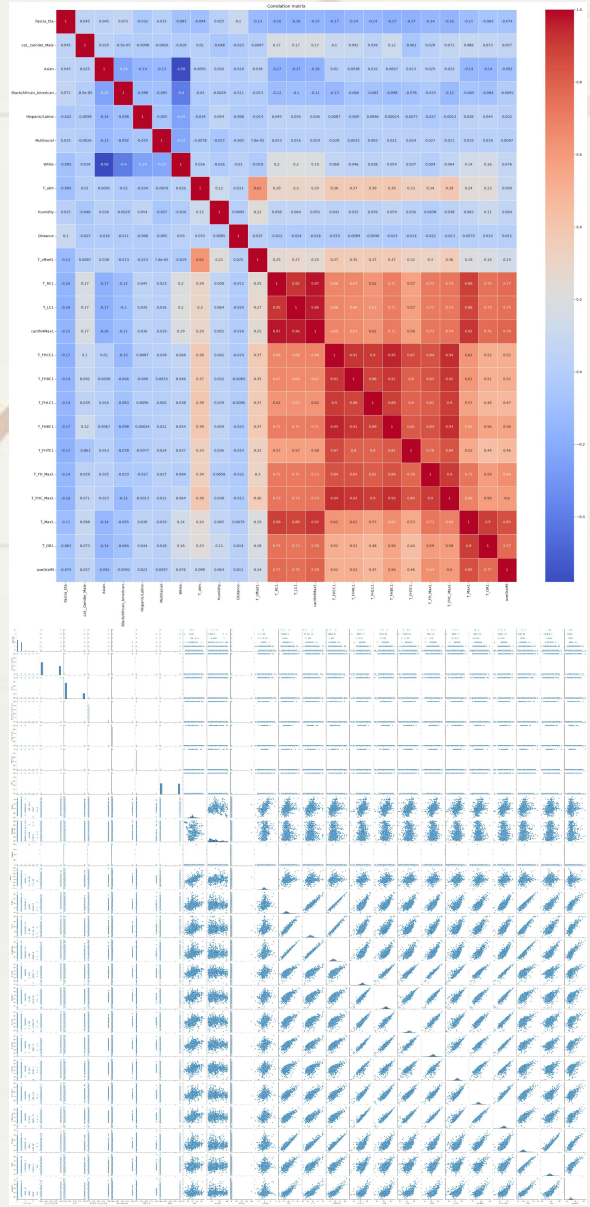
- ***MATRICE DI CORRELAZIONE E SELEZIONE FEATURE***: Le temperature facciali sono fortemente correlate perchè più letture della stessa area portano quasi la stessa informazione e rendendo instabili i coefficienti dei modelli lineari.
  Per ogni zona si è cercato di adottare un approccio che mantenesse l'informazione della temperatura massima e la compensasse con una media per attenuare il rumore del sensore:
  - **canthi e bocca:** la media dei 4 pixel più caldi (T_RC1, T_LC1, canthi4Max1, T_OR1) al posto del massimo sul singolo pixel.
  - **fronte:** non erano disponibili le medie dei 4 pixel più caldi pertanto si sono mantenute le medie delle regioni presenti e i valori di picco.
  - **volto intero:** T_Max1 che era la feature con maggiore correlazione con la label.

➔ Dopo aver selezionato le feature, sono stati prodotti i sottoinsiemi di train e test.
Le feature (solo feature continue) sono state poi **standardizzate,** escludendo le label nel processo per evitare il data leakage.

3. EDA

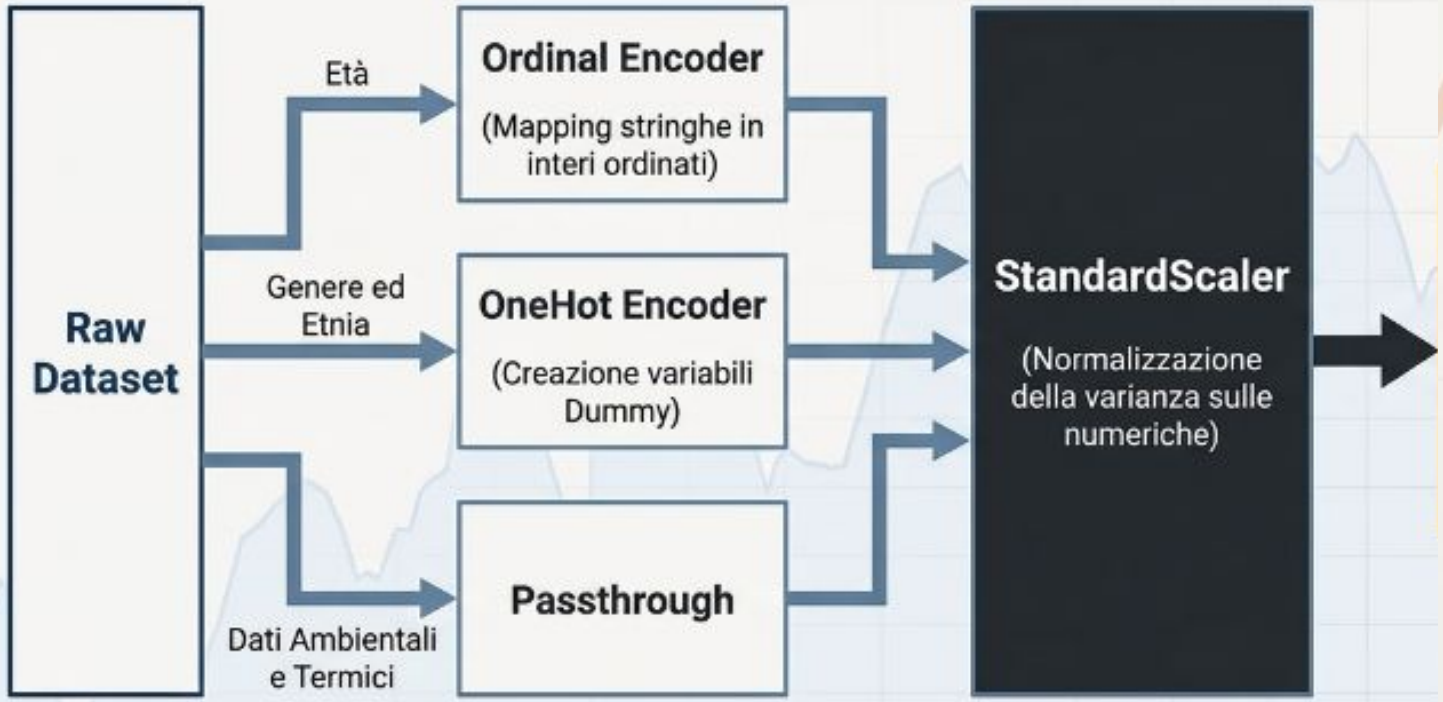

Correlation matrix
Fascia_Eta
cat__Gender_Male
Asian
Black/African_American
Hispanic/Latino
Multiracial
White
T_atm
Humidity
Distance
T_offset1
Max1R13_1
Max1L13_1
aveAllR13_1
aveAllL13_1
T_RC1
T_RC_Dry1
T_RC_Wet1
T_RC_Max1
T_LC1
T_LC_Dry1
T_LC_Wet1
T_LC_Max1
RCC1
LCC1
canthiMax1
canthi4Max1
T_FHCC1
T_FHRC1
T_FHLC1
T_FHBC1
T_FHTC1
T_FH_Max1
T_FHC_Max1
T_Max1
T_OR1
T_OR_Max1
aveOralM

38



23

Data Engineering: La Pipeline di Preprocessing

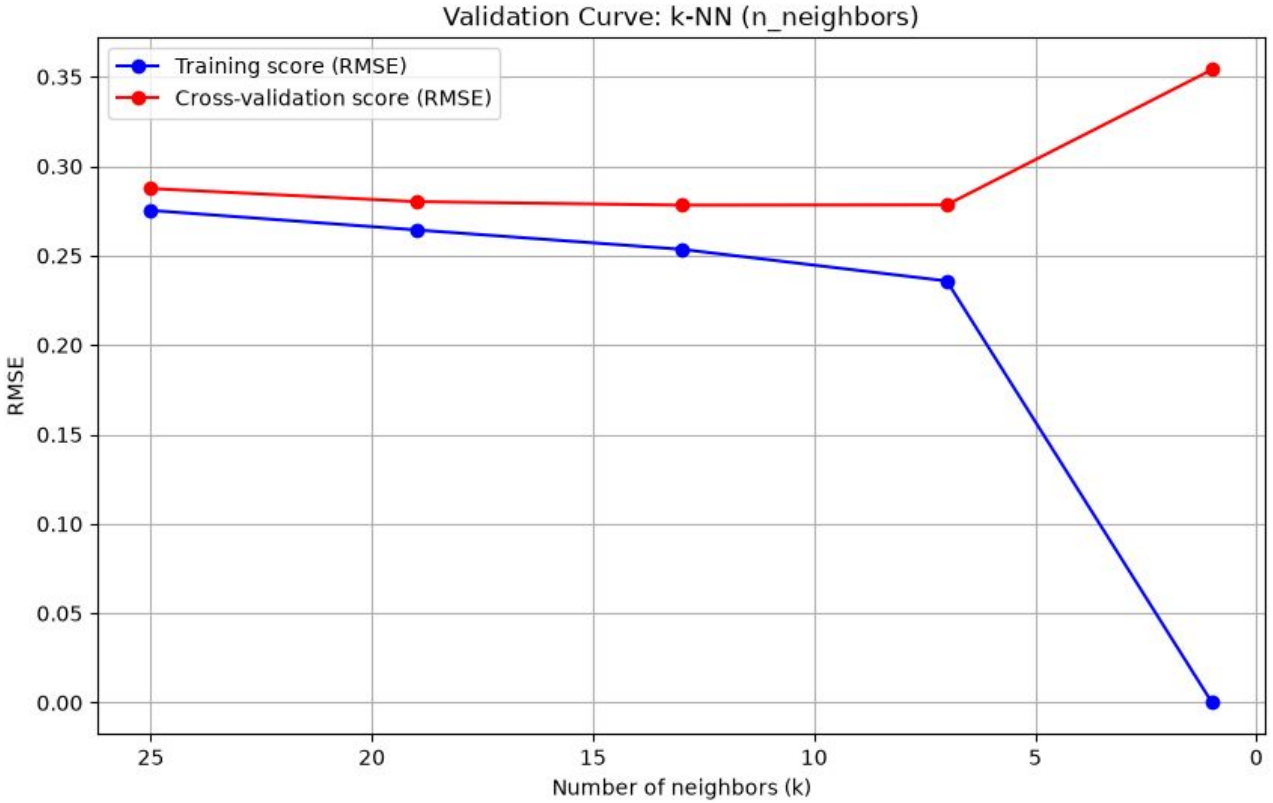


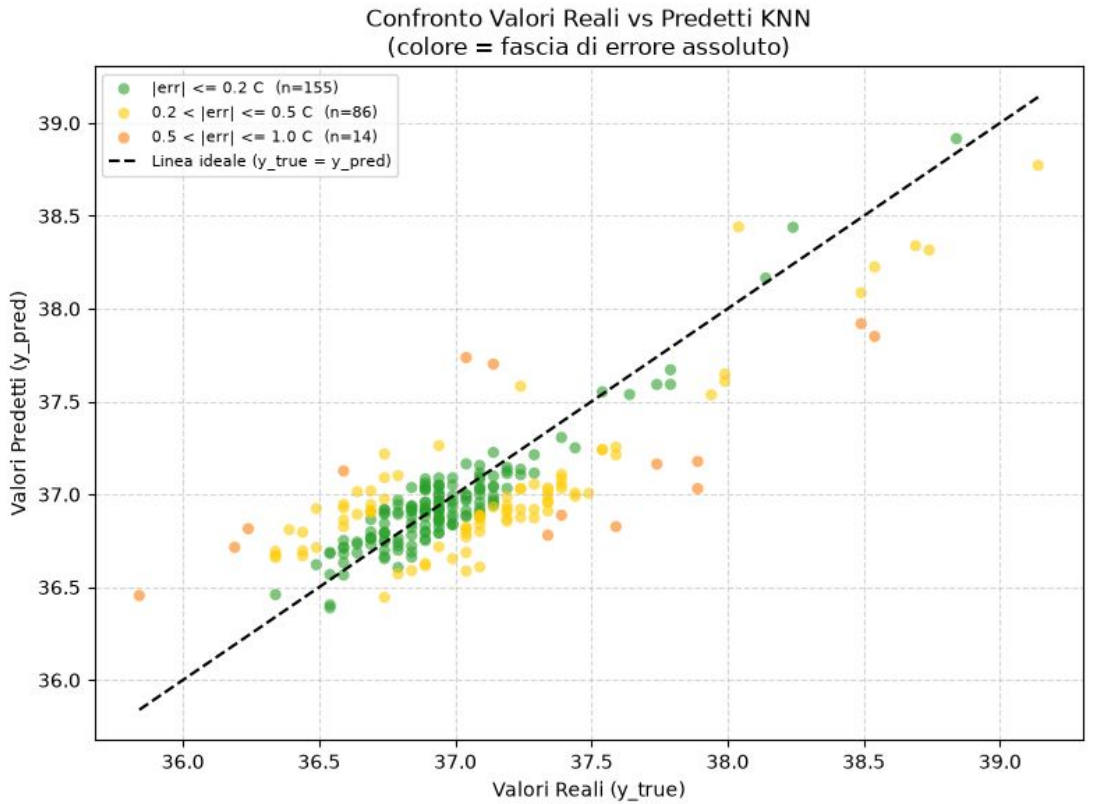
Nota metodologica: I target (label y) non sono stati standardizzati.

4. MODELLI

1. K-NN
2. DECISION TREE
3. REGRESSORE LINEARE
    a. SEMPLICE
    b. RIDGE
    c. LASSO
4. NN
5. REGRESSORE LINEARE CON PCA

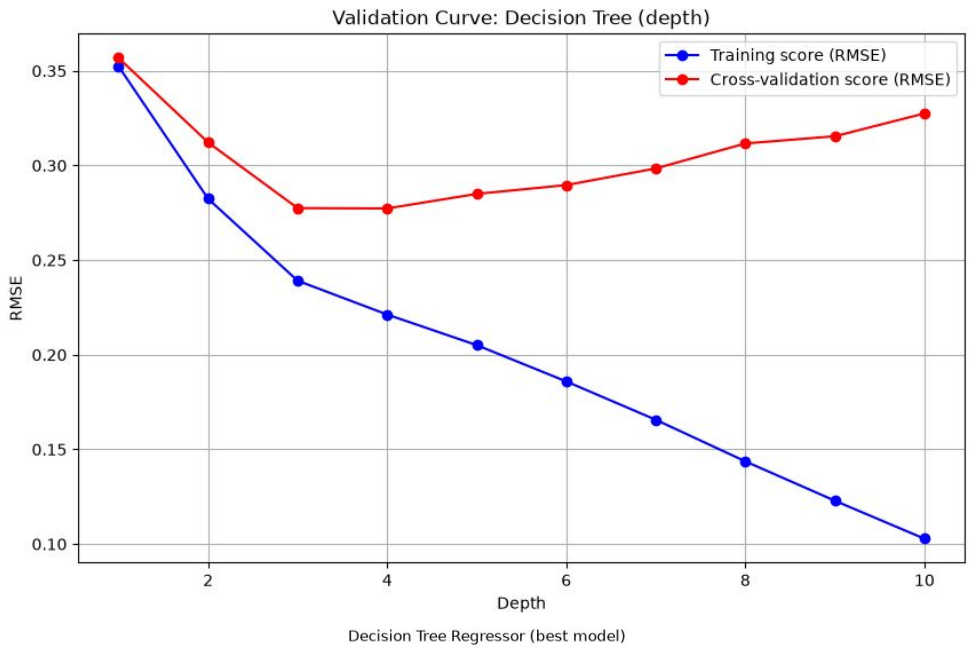
4.1 MODELLI: K-NN (K = 13)



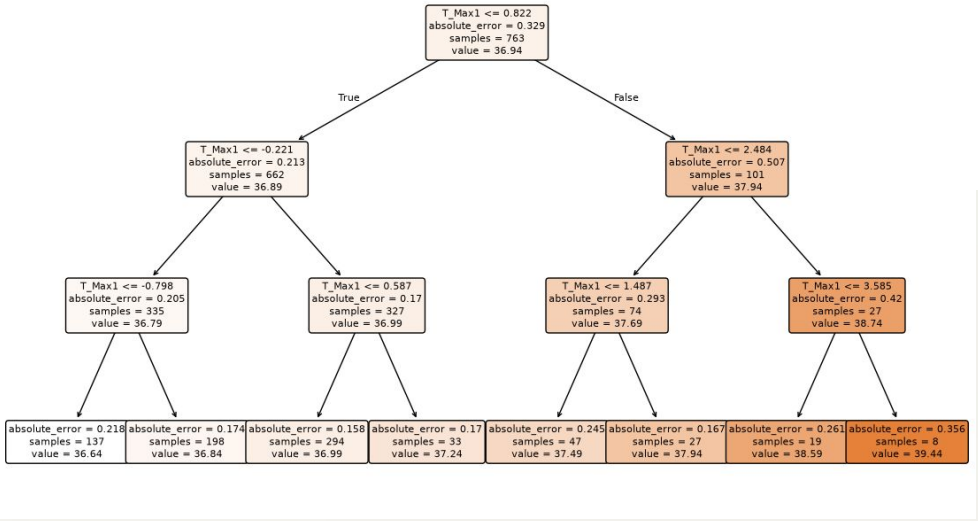


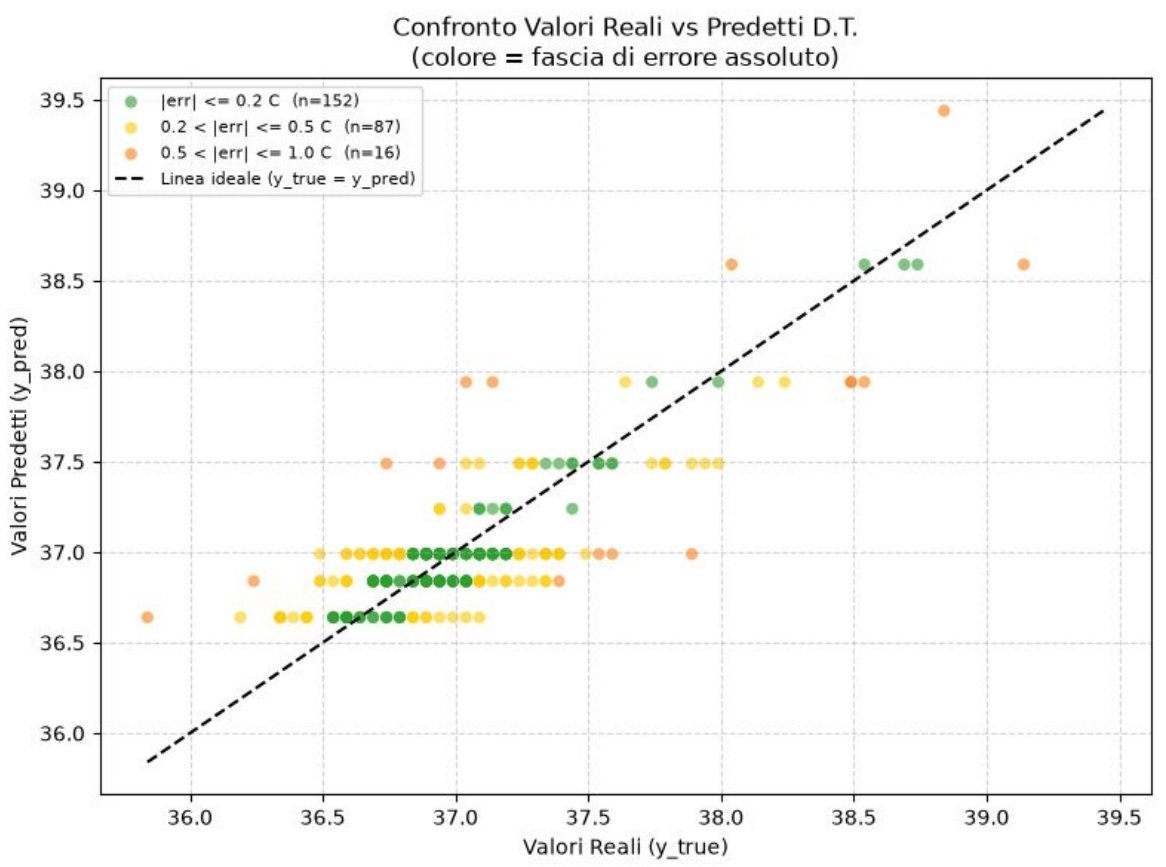
Non performa bene nelle code in cui ci sono pochi sample. Nella parte a maggiore densità di campioni riesce a modellare bene il fenomeno.
Nella parte a maggiore densità riesce a modellare bene il fenomeno.

4.2 MODELLI: DECISION TREE (d = 3)



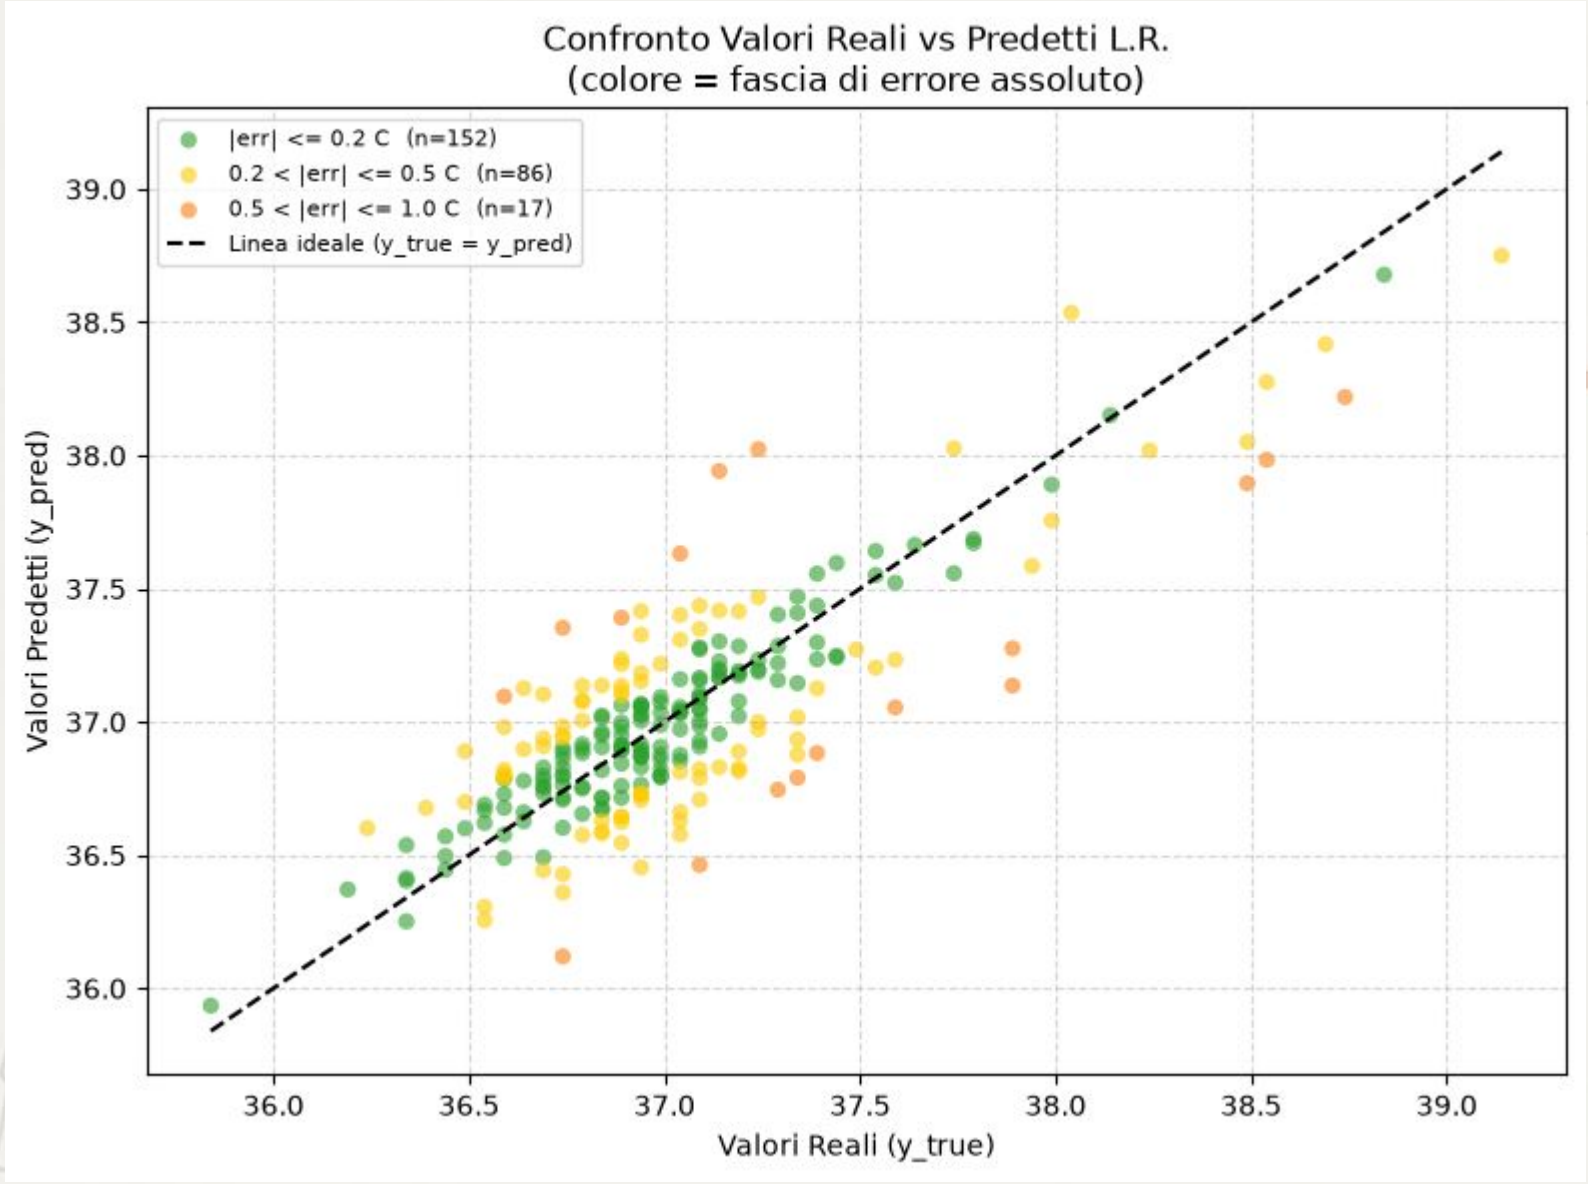
Decision Tree Regressor (best model)





Pur garantendo buone performance sull'errore, gli alberi decisionali non generano una funzione di regressione continua, restituiscono infatti una stima a tratti costante, modellata attraverso una serie di iperpiani ortogonali agli assi.
Inoltre, i punti nelle code della retta non sono così significativi da introdurre altri "batch".

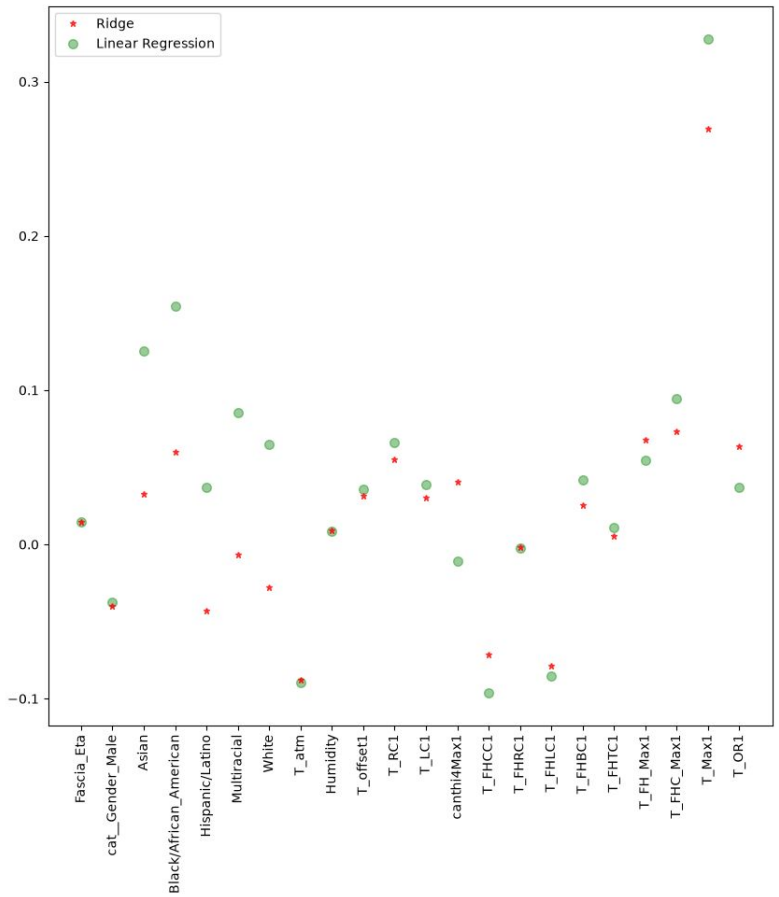
4.3.a MODELLI: LINEAR REGRESSION

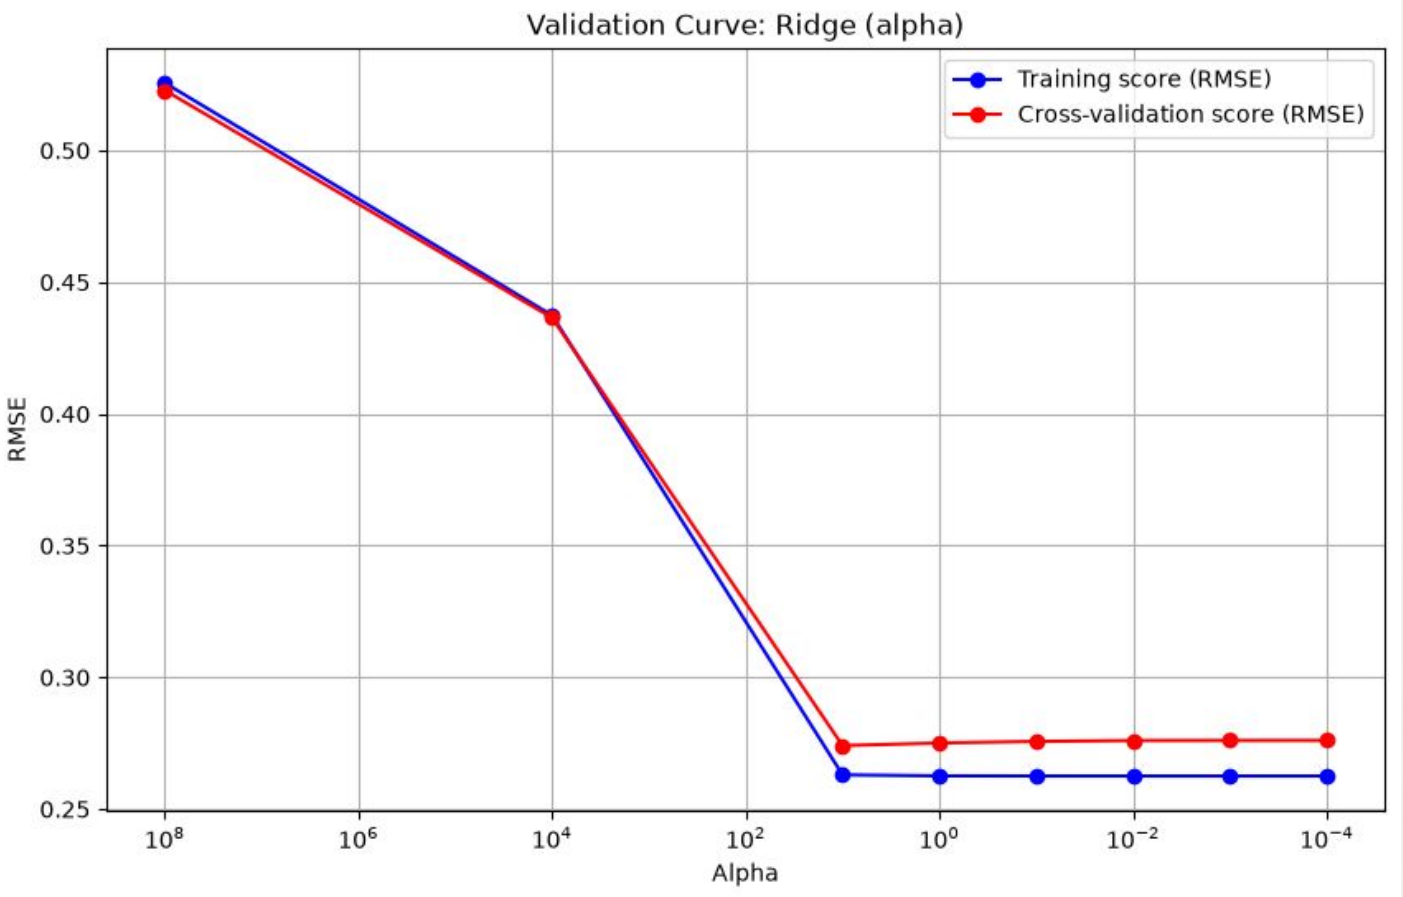


Si prosegue con il modello lineare per ragioni strutturali:

- fornisce una stima continua, a differenza dell'albero;
- può estrapolare oltre i valori dei vicini, cosa che il K-NN non può fare
- ha coefficienti leggibili
- si presta alla regolarizzazione, che affronta la collinearità emersa nell'EDA.

4.3.b MODELLI: RIDGE



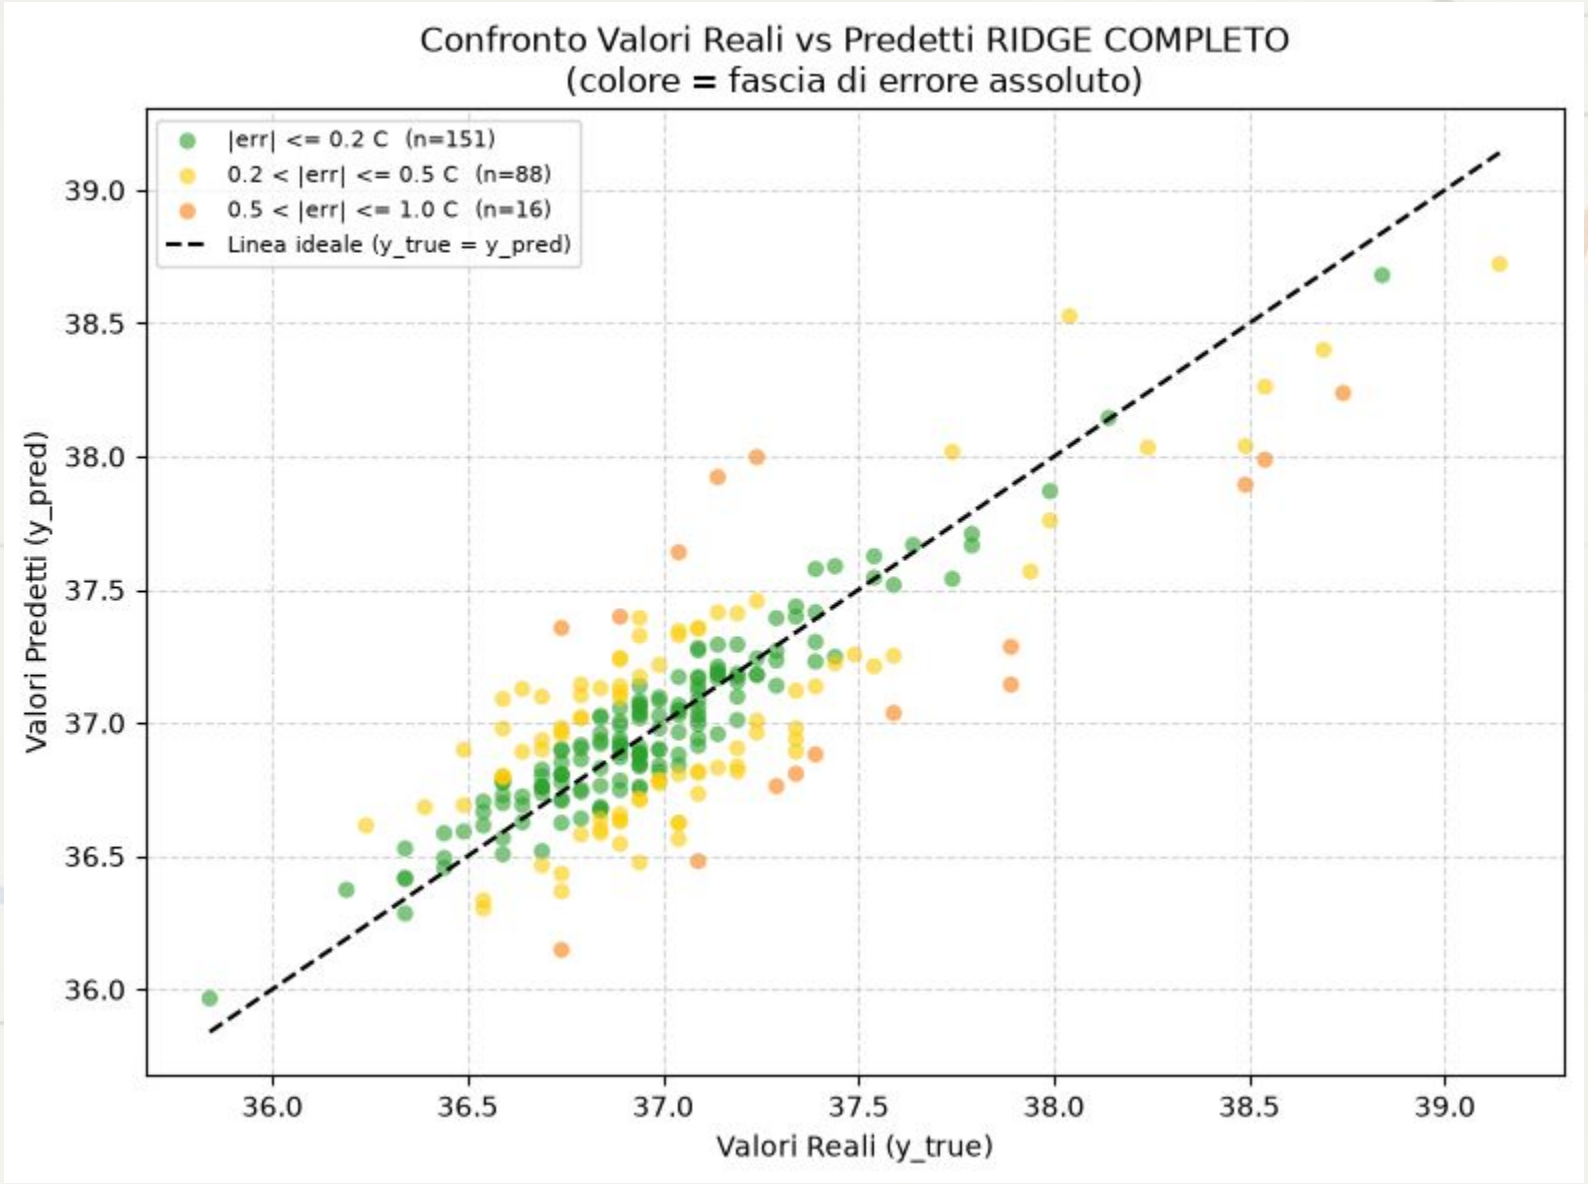



```
_____________________RIDGE DS COMPLETO_____________________

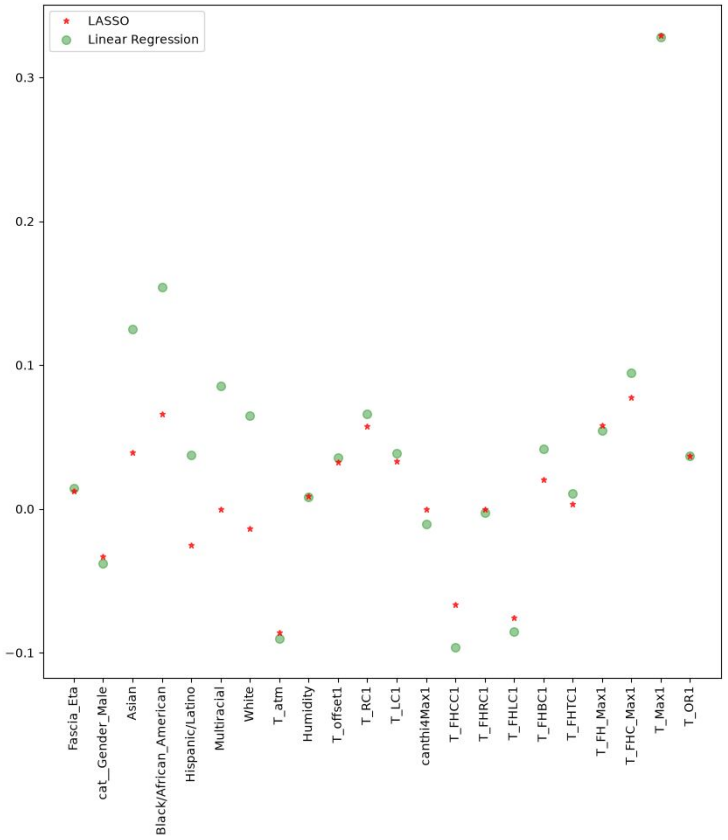
Alpha scelto da RidgeCV: 10.0

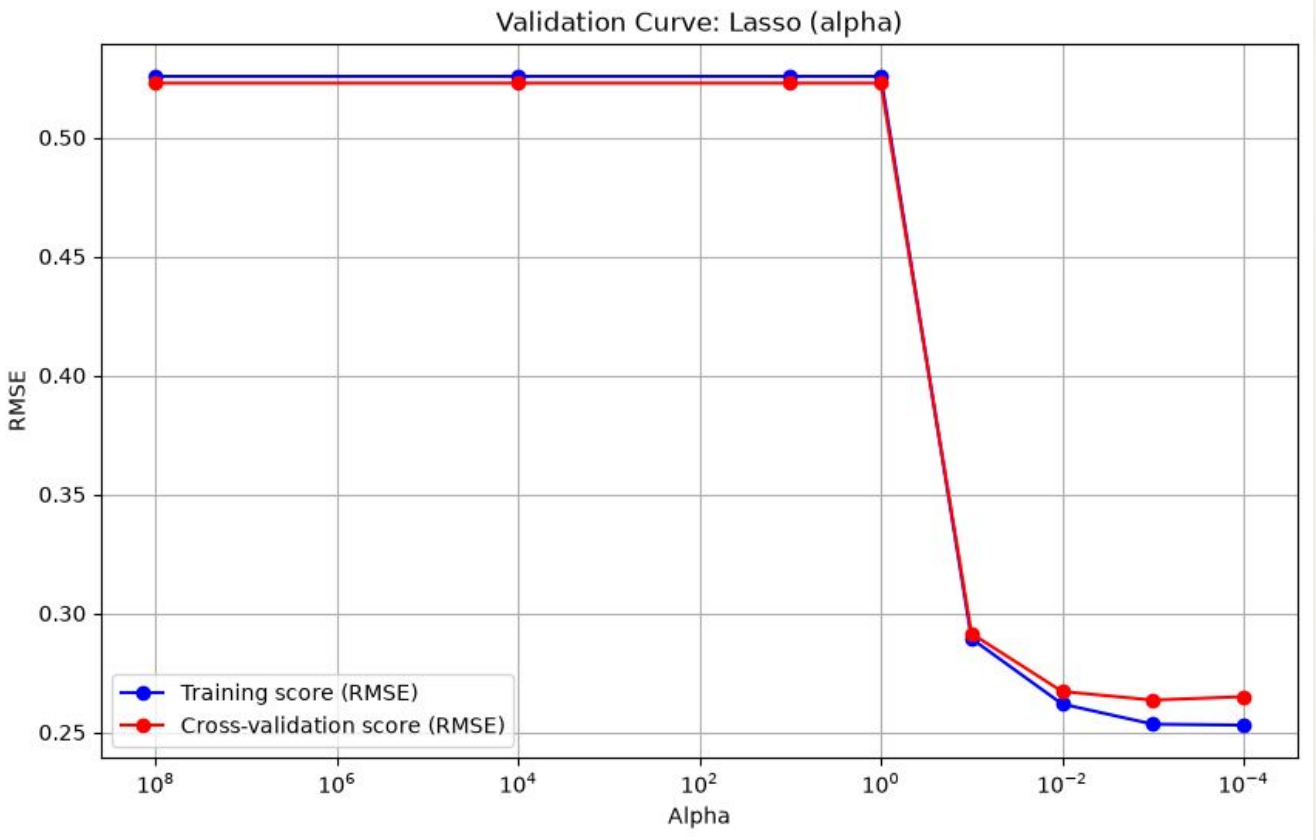
_____________________________________________________________
Coefficienti: [ 0.01429319 -0.03966284  0.03300372  0.05995308 -0.04305659 -0.00665979
 -0.02783691 -0.08787869  0.00905357  0.03130908  0.05516721  0.03048167
  0.04048682 -0.07156154 -0.00152146 -0.07849691  0.02543735  0.00550577
  0.06803152  0.07338912  0.26974643  0.0634015 ]
Intercetta: 37.03214951771604
```

4.3.b MODELLI: RIDGE



4.3.c MODELLI: LASSO





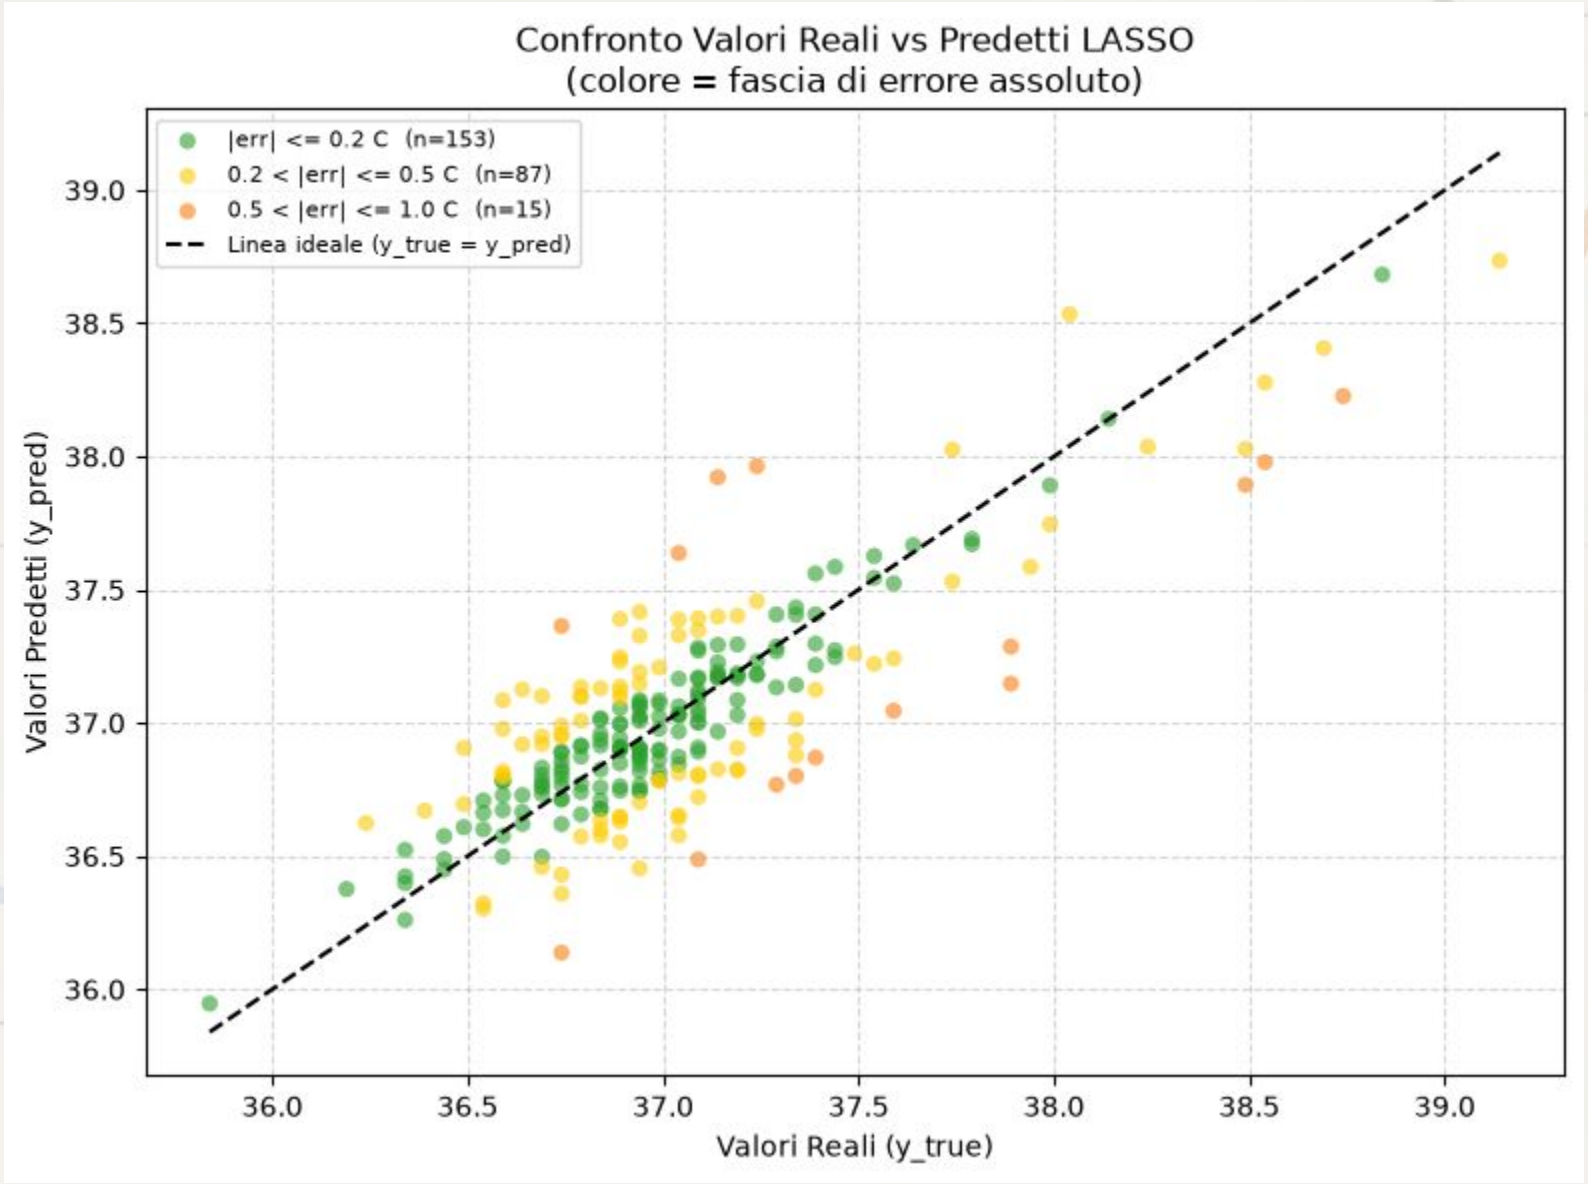

```
_____________Lasso Model DS COMPLETO_____________

Alpha scelto da LassoCV: 0.001

_____________________________________________________________
Coefficienti: [ 0.01257414 -0.03322839  0.03930338  0.06595713 -0.02520792  0.
 -0.01350177 -0.08608927  0.00863404  0.03245511  0.05770524  0.03299653
  0.         -0.06621296  0.         -0.07543673  0.02057936  0.00347006
  0.05839033  0.07775097  0.32936408  0.03690706]
Intercetta: 37.01967583163099

_____________________________________________________________
```

4.3.c MODELLI: LASSO



4.3.b\c: OSSERVAZIONI SUI MODELLI REGOLARIZZATI

Ridge e Lasso riducono la varianza dei coefficienti e migliorano la stabilità predittiva mantenendo un'elevata spiegabilità clinica. Si possono notare nei coefficienti ridisegnati delle similitudini significative in alcuni predittori.

Fascia_Eta, genere, T_atm, Humidity, Distance e T_offset1 hanno praticamente lo stesso coefficiente nei tre modelli: sono poco correlate con le altre feature e il loro effetto è ben identificato.

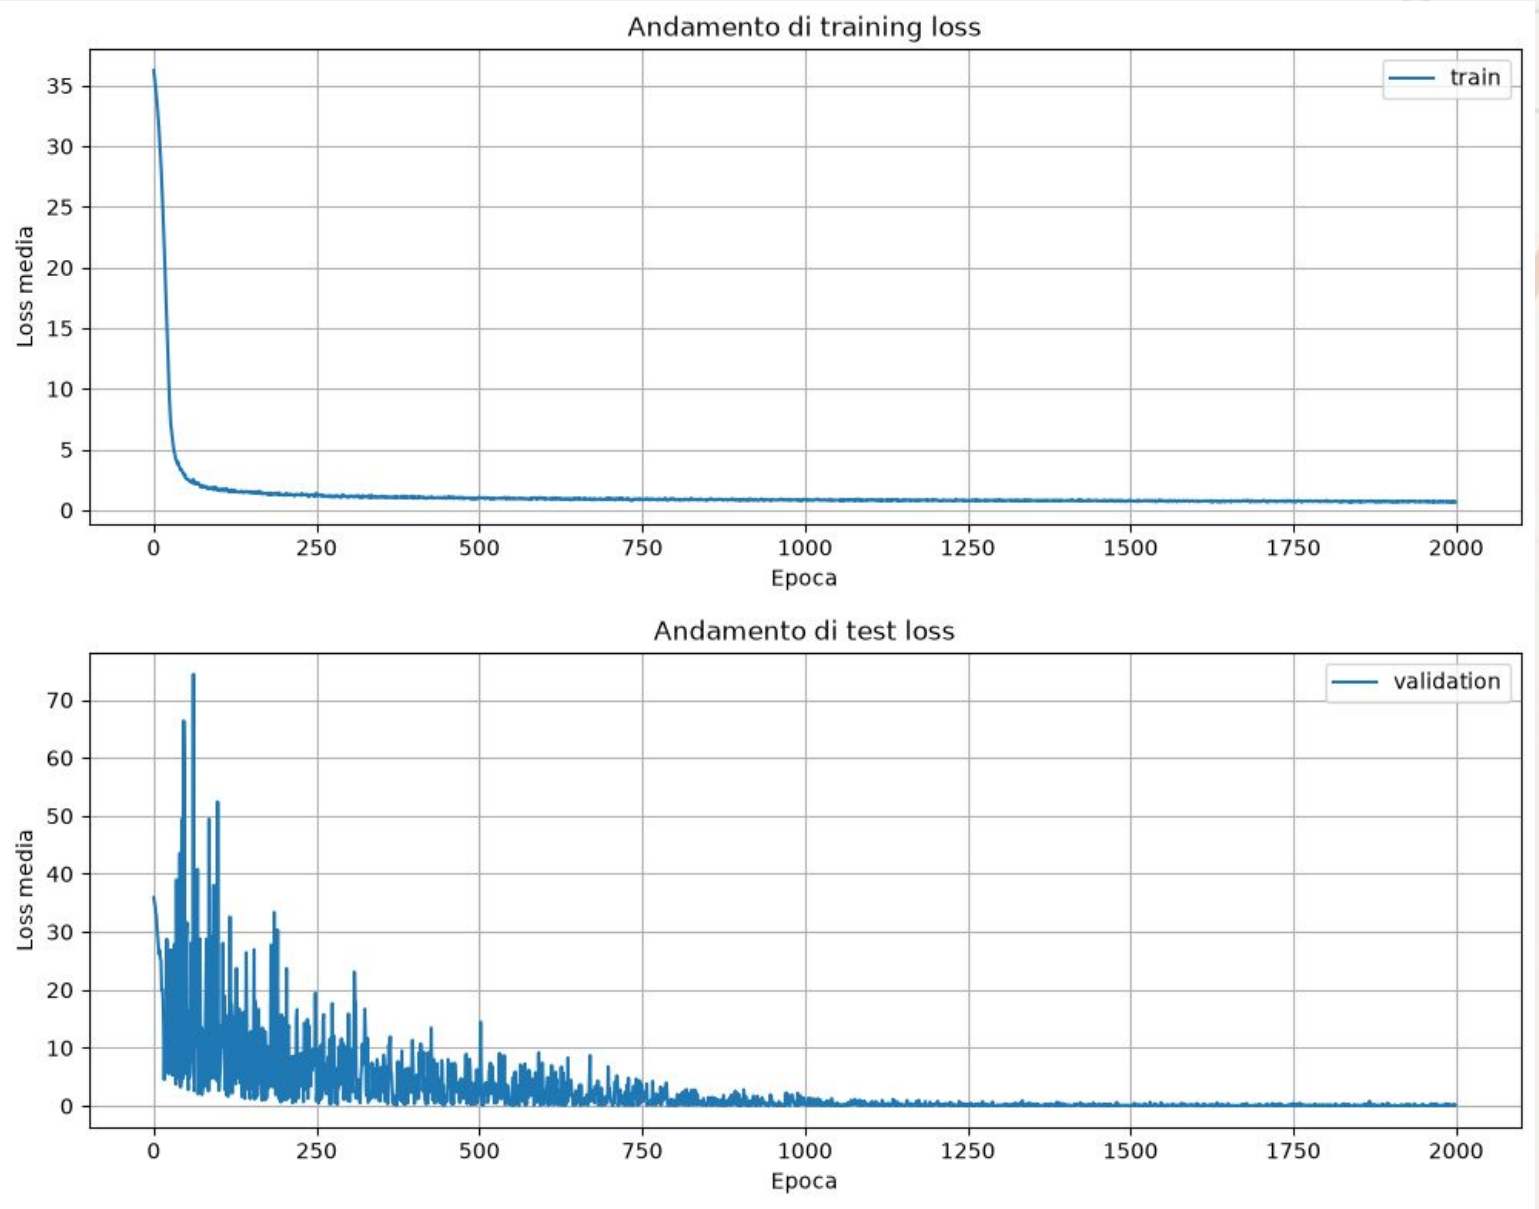
T_Max1 è in ogni caso il predittore dominante.

I cinque coefficienti delle dummy di etnia scendono tutti di una quantità quasi uguale, mentre le loro differenze reciproche restano simili. Poiché le dummy sommano quasi a una costante, il loro livello comune è collineare con l'intercetta. **Sono quindi interpretabili solo le differenze tra gruppi, non i valori assoluti.**

Sulle temperature facciali, fortemente correlate tra loro, i due metodi si comportano in modo diverso. L**ASSO, per la geometria della penalità L1, produce zeri esatti**, **Ridge non azzera nulla**, ma riduce T_Max1 (da circa 0,33 a 0,27) e ne ridistribuisce il peso sulle feature correlate.

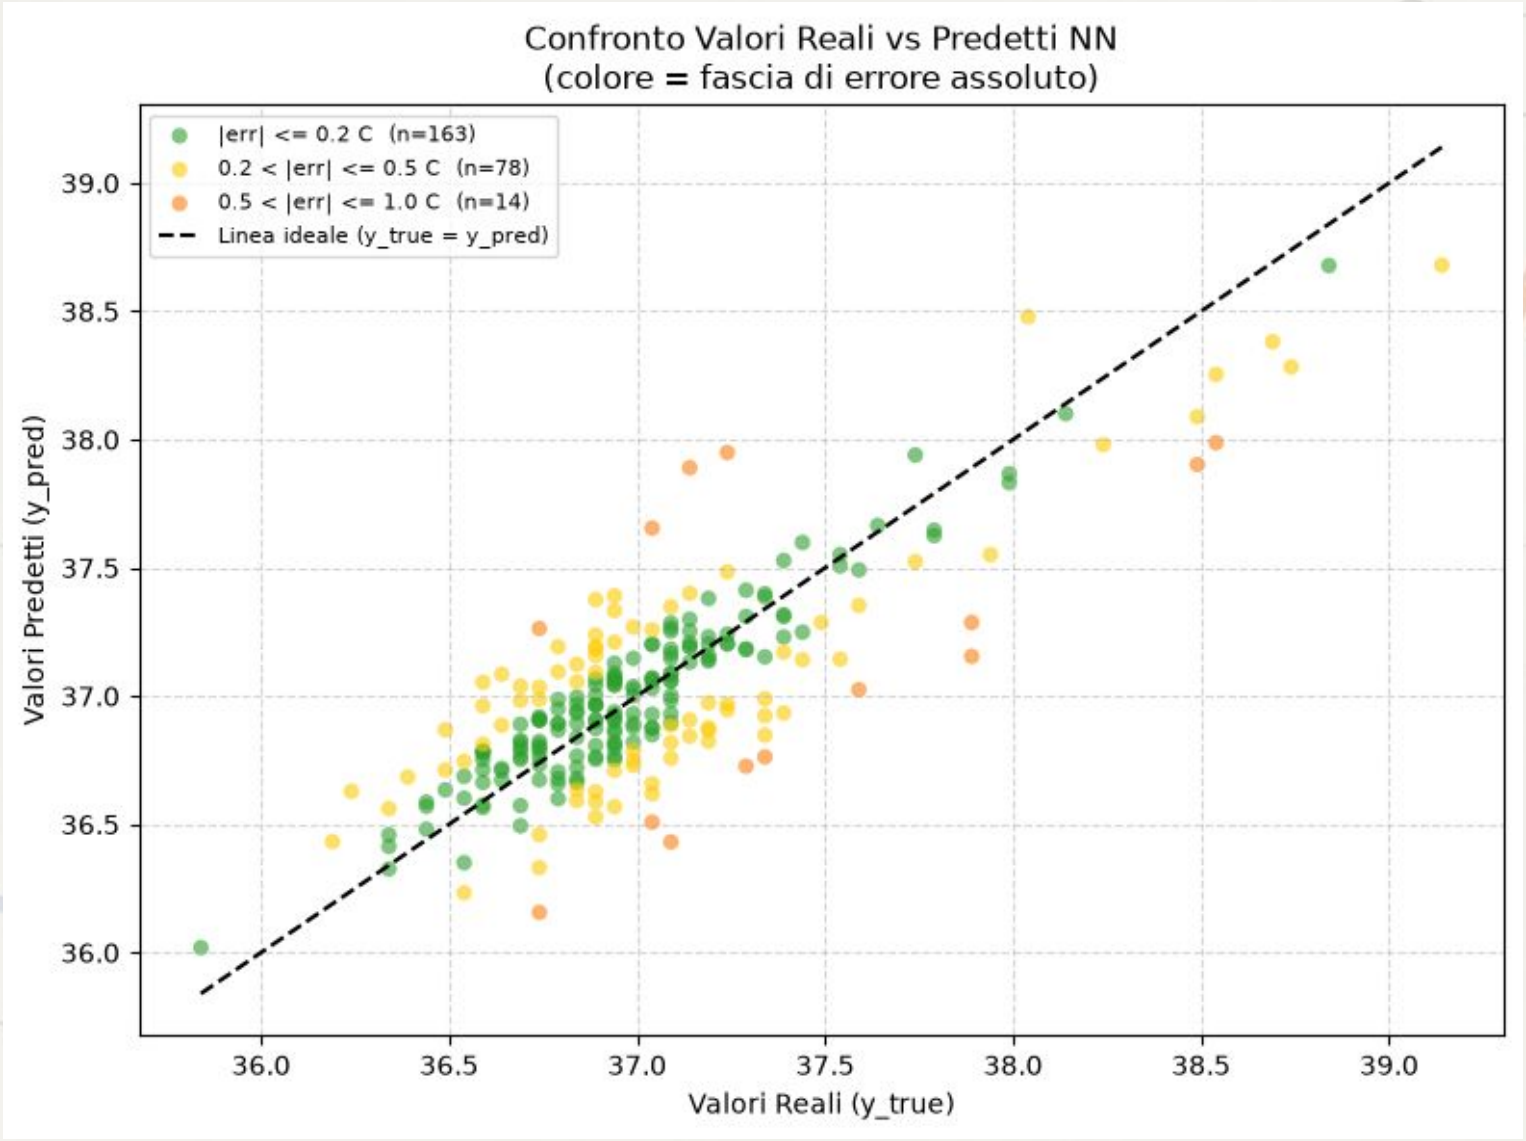
4.4 MODELLI: NN

Proviamo un altro approccio rispetto a quello lineare. Riceve feature non standardizzate.



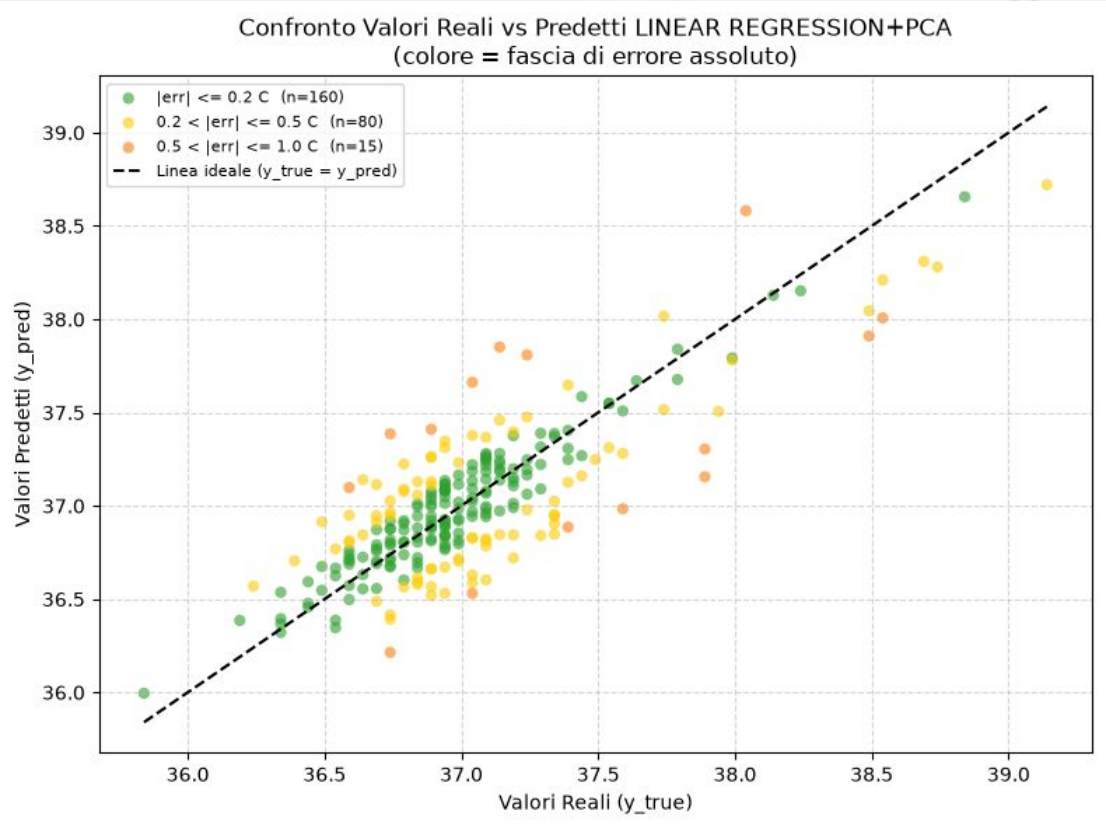
4.4 MODELLI: NN

La non linearità non porta un guadagno apprezzabile



MODELLI: LINEAR REGRESSION+PCA {95% VARIANZA}

Tentativo sperimentale: PCA su dataset per via dell'alta correlazione.




```
_____________Linear Regression con PCA_____________

_____________________________________________________________
Numero di componenti principali usate: 11
Coefficienti (sulle componenti PCA): [ 0.12081451 -0.17765105  0.03854698  0.02262068  0.04910693  0.05310597
 -0.14782646  0.0299796   0.065314   -0.03809771  0.01715602]
_____________________________________________________________
```

RISULTATI

- Lo studio di riferimento (Wang et al., 2022) considera clinicamente affidabile un sistema IRT che mantenga una deviazione standard dell'errore inferiore a 0.3 °C.
  - Gli RMSE ottenuti (0.25), con bias praticamente nulli, equivalgono alla deviazione standard e soddisfano il limite.
  - Il MAE, più basso (≈0.19), indica che l'errore sul paziente tipico è ben inferiore ed è concentrato in poche istanze estreme.

```
_____________ DATASET DI PARTENZA _____________

Test RMSE (D): 0.9856
Test MAE  (D): 0.9480
Test R^2  (D): -3.6627
MAX ERROR  (D): 1.7575
Test bias (D): 0.9480
```



```
=======================================================
CONFRONTO PERFORMANCE MODELLI
=======================================================
      Modello     RMSE      MAE      R^2  MAX ERROR
          K-NN 0.253078 0.196717 0.692595   0.858617
Decision Tree 0.263647 0.203137 0.666382   0.900000
   Linear Reg 0.252810 0.196377 0.693245   0.801726
        Ridge 0.250088 0.194766 0.699815   0.782567
        Lasso 0.250462 0.194428 0.698918   0.782175
   PCA+Linear 0.247324 0.192782 0.706413   0.735094
           NN 0.245427 0.191174 0.710900   0.752258
=======================================================
```

- Una interessante conclusione dello studio è il fatto che le feature relative all'etnia e all'età del soggetto hanno una importanza marginale nella misura rispetto a quella prevista.
- **L'errore iniziale è quasi interamente un offset sistematico (0,95 °C). Una regressione lineare sul solo T_Max1 porta l'RMSE a 0,26; le altre 22 feature forniscono un contributo marginalmente.**
- Tuttavia, è necessario mitigare il **problema dell'errore massimo**.

RISULTATI - FAIRNESS/ERRORE MAX

Per completare lo studio si è scelto di eseguire una **analisi di fairness** su ciascun modello, in quanto, consapevolmente, non era stato affrontato il problema dello squilibrio delle classi avendo ottenuto risultati promettenti nella modellazione.

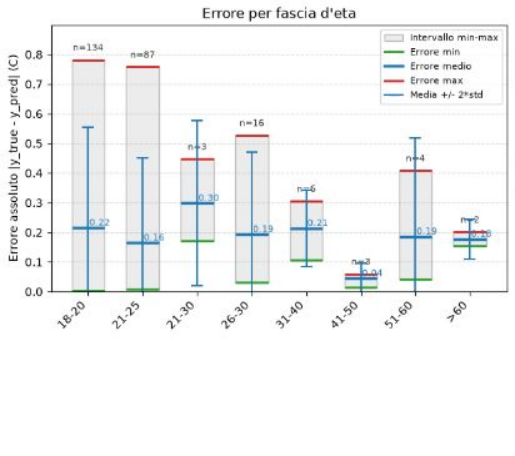
Come anticipato, in alcune categorie, l'analisi statistica non è rilevante a causa dell'esiguo numero di campioni.

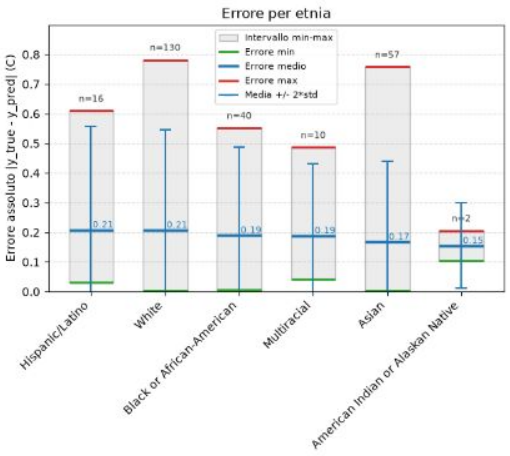
Riguardo all'errore massimo si sono sviluppate 3 ipotesi:

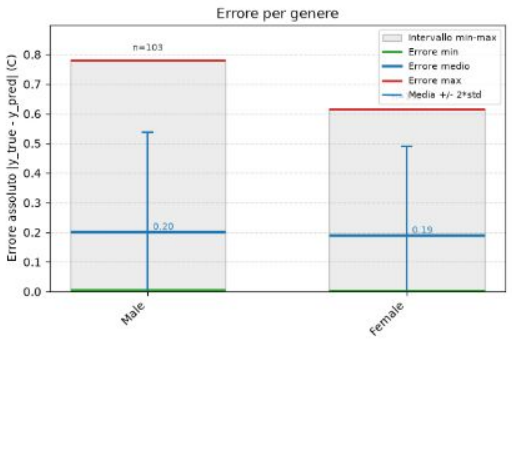
1. Le feature non contengono tutta l'informazione necessaria alla predizione.
2. I sample che sono interpolati in maniera errata sono rumorosi.
3. Problema di fairness e sottorappresentazione.

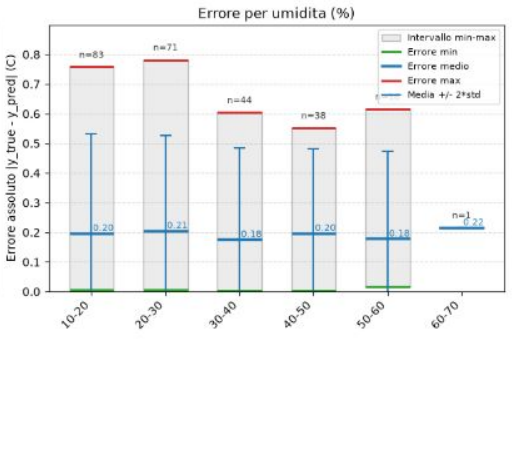
RISULTATI

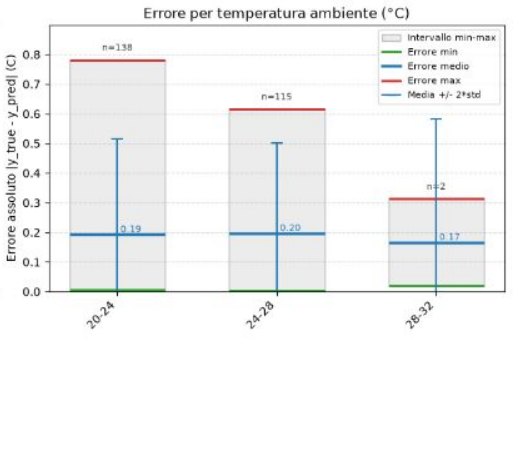
Analisi errore per categoria - Ridge



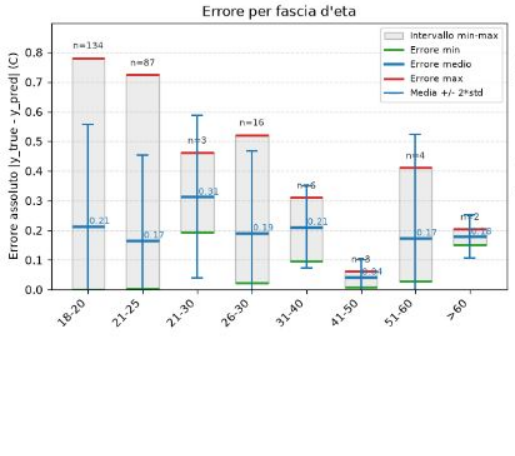


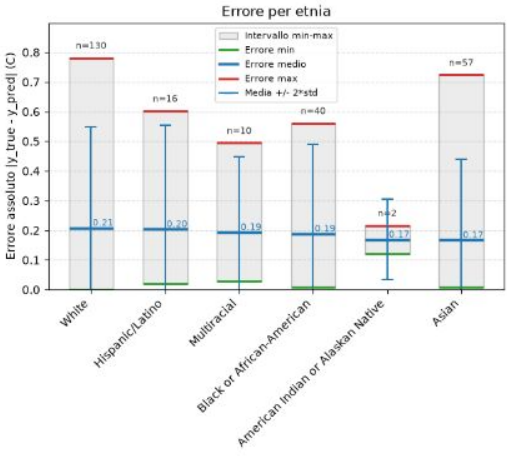


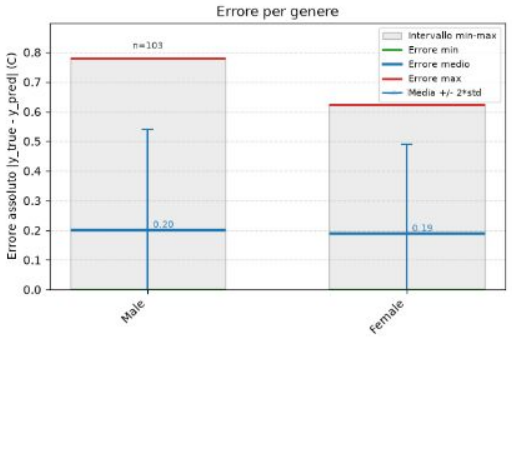


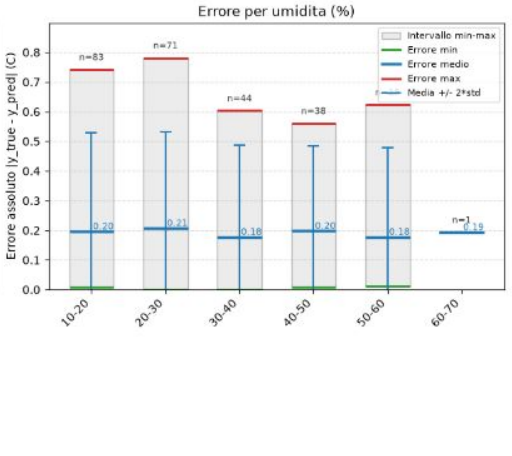


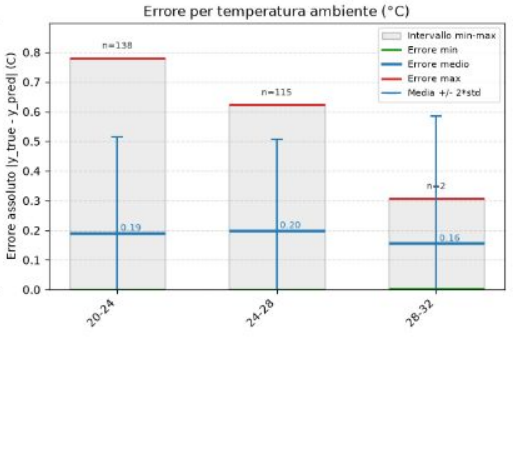
Analisi errore per categoria - Lasso



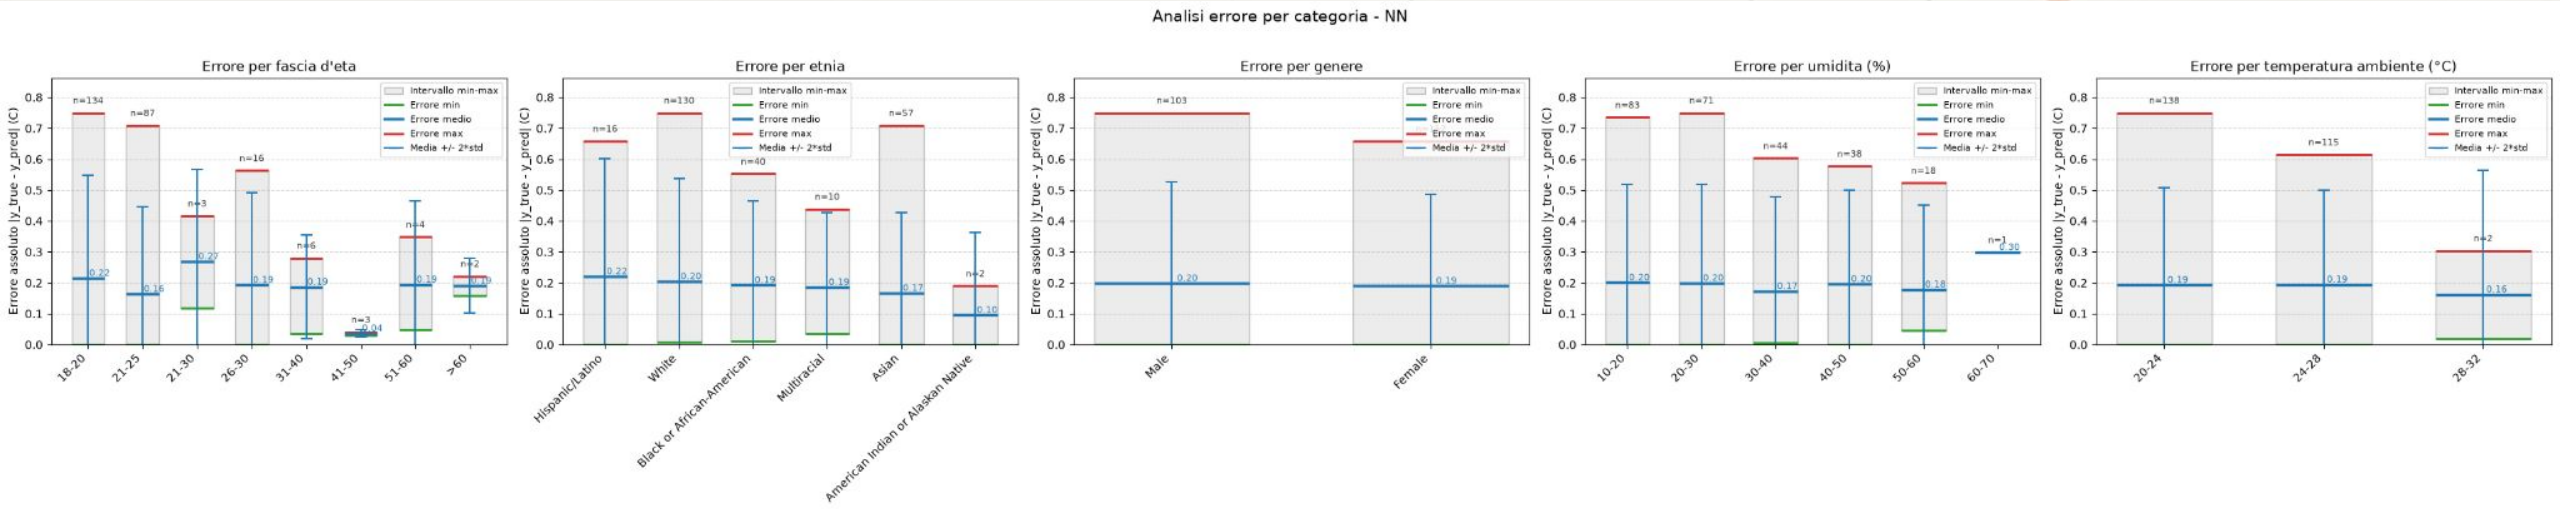








RISULTATI


Analisi errore per categoria - NN
Errore per fascia d'eta
Errore per etnia
Errore per genere
Errore per umidita (%)
Errore per temperatura ambiente (°C)
Errore assoluto |y_true - y_pred| (C)
Intervallo min-max
Errore min
Errore medio
Errore max
Media +/- 2*std
18-20
21-25
21-30
26-30
31-40
41-50
51-60
>60
Hispanic/Latino
White
Black or African-American
Multiracial
Asian
American Indian or Alaskan Native
Male
Female
10-20
20-30
30-40
40-50
50-60
60-70
20-24
24-28
28-32

RISULTATI

L’analisi di fairness non ha evidenziato comportamenti squilibrati tra classi: la media dell’errore e la distribuzione degli errori stessi risultano simili per ogni classe. L’unica classe in cui i valori non sono uniformi è quella relativa all’età (a causa probabilmente di classi con pochi sample).

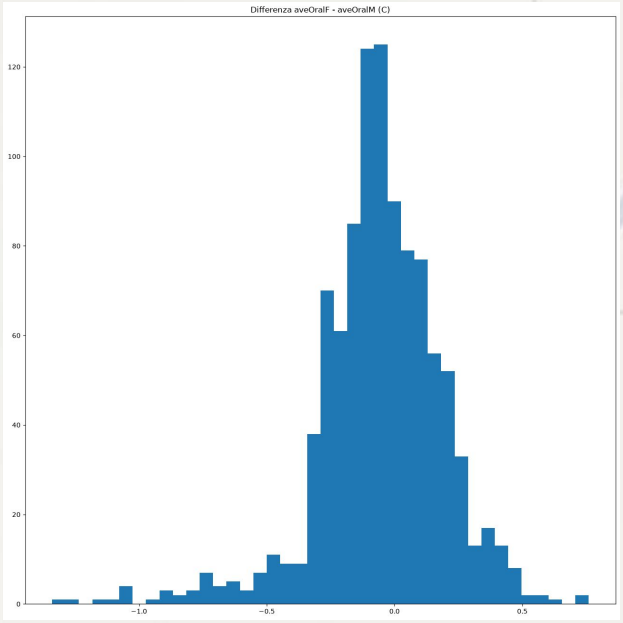
Tuttavia, si può notare che nelle classi con **più campioni presentano un errore maggiore**, pertanto, si è escluso che l’errore dipenda dalle classi sottorappresentate.

Nelle previsioni si può notare anche un fenomeno di **regressione verso la media**: nello scatter plot, i valori nelle code sono sottostimati, per temperature >38°C, e sovrastimati per temperature <36.5°C. Il modello, minimizzando l'errore quadratico, tira le previsioni verso il centro, dove sta la maggior parte dei dati. Questo, tuttavia, **non risulta essere un problema serio nella regressione dal punto di vista dell’errore ma potrebbe rappresentare una criticità in una eventuale diagnosi di sintomi febbrili.**

CONCLUSIONE

Gli errori superiori a 0.5 °C non sono riconducibili a errori di misura, date le discordanze evidenti tra le due tipologie di misure orali di riferimento in un solo caso su 16, né, fatta eccezione per due casi, ad anomalie nelle acquisizioni delle regioni della fronte da parte del dispositivo IRT. L'errore residuo è compatibile con la combinazione di rumore di misura del target (circa 0.25 °C di dispersione tra le due misure orali), la variabilità fisiologica non catturata dalle feature disponibili e la tendenza del modello a sottostimare le temperature elevate, poco rappresentate nel training.

I dati disponibili non consentono di separare il contributo dell'errore strumentale della termocamera da quello delle variabili non osservate.



Label aveOralM fuori da [35.0, 40.5] C: 0

	aveOralF	aveOralM	diff	abs_diff

Soglia di discordanza: 0.667 C dallo scostamento mediano (-0.040 C)
Label sospette: 26 su 1020

	aveOralF	aveOralM	diff	abs_diff	sospetta
751	37.15	38.49	-1.34	1.34	True
495	37.45	38.69	-1.24	1.24	True
358	37.30	38.44	-1.14	1.14	True
78	37.45	38.54	-1.09	1.09	True
132	37.35	38.39	-1.04	1.04	True
72	37.65	38.69	-1.04	1.04	True
874	37.90	38.94	-1.04	1.04	True
129	36.95	37.99	-1.04	1.04	True
292	37.35	38.29	-0.94	0.94	True
774	36.85	37.74	-0.89	0.89	True
721	37.00	37.89	-0.89	0.89	True
686	37.40	38.29	-0.89	0.89	True
314	36.90	37.74	-0.84	0.84	True
836	37.35	38.19	-0.84	0.84	True
839	38.30	39.09	-0.79	0.79	True
93	37.00	37.79	-0.79	0.79	True
791	37.15	37.94	-0.79	0.79	True
112	36.40	35.64	0.76	0.76	True
823	36.85	37.59	-0.74	0.74	True
212	36.90	37.64	-0.74	0.74	True
122	39.60	40.34	-0.74	0.74	True
150	37.25	37.99	-0.74	0.74	True
747	37.00	37.74	-0.74	0.74	True
128	36.70	37.44	-0.74	0.74	True
837	37.20	37.94	-0.74	0.74	True
320	36.70	35.99	0.71	0.71	True

-- Punti con errore > 0.5 --

	T_FHCC1	T_FHRC1	T_FHLC1	T_FHBC1	T_FHTC1	T_FH_Max1	scarto_fh	gap_max	y_true	y_pred	err	abs_err
741	34.542	35.275	34.588	34.735	34.878	36.015	0.733	1.473	37.14	37.922	-0.782	0.782
887	34.988	34.448	35.178	35.028	33.108	35.700	2.070	2.593	37.89	37.148	0.742	0.742
924	32.710	34.448	32.252	33.518	31.962	35.902	2.485	3.940	37.24	37.966	-0.726	0.726
514	34.215	34.138	34.400	34.122	33.828	35.070	0.572	1.242	36.74	37.364	-0.624	0.624
722	34.408	34.655	34.728	34.380	34.245	35.162	0.483	0.918	37.89	37.285	0.605	0.605
854	33.483	33.707	34.057	33.067	33.627	34.453	0.990	1.387	36.74	36.137	0.603	0.603
464	33.840	33.822	34.222	33.680	34.122	35.095	0.542	1.415	37.09	36.488	0.602	0.602
664	35.508	35.562	35.778	35.502	35.642	36.175	0.275	0.672	37.04	37.638	-0.598	0.598
751	35.738	35.842	35.852	35.842	35.702	36.148	0.150	0.445	38.49	37.894	0.596	0.596
754	34.758	34.765	34.800	34.945	34.478	36.268	0.468	1.790	38.54	37.979	0.561	0.561
344	34.470	34.392	34.382	34.522	34.800	35.162	0.417	0.780	37.59	37.046	0.544	0.544
411	34.218	34.170	34.118	34.035	33.770	34.712	0.447	0.942	37.34	36.801	0.539	0.539
1018	34.840	35.020	34.925	34.715	34.595	35.415	0.425	0.820	37.29	36.768	0.522	0.522
685	34.465	34.852	34.555	34.380	34.750	35.512	0.472	1.133	37.39	36.871	0.519	0.519
998	36.168	36.085	36.130	36.168	35.215	36.935	0.952	1.720	38.74	38.228	0.512	0.512
519	34.668	34.892	34.452	34.432	34.865	36.125	0.460	1.693	36.89	37.392	-0.502	0.502

-- Statistiche degli indicatori per gruppo --

	scarto_fh				gap_max			
	count	median	mean	max	count	median	mean	max
gruppo								
alto	16	0.477	0.746	2.485	16	1.315	1.435	3.940
basso	204	0.405	0.472	2.350	204	1.013	1.079	2.718
intermedio	35	0.360	0.452	1.788	35	1.125	1.122	2.575

-- Numero di punti per gruppo e fascia di scarto della fronte --

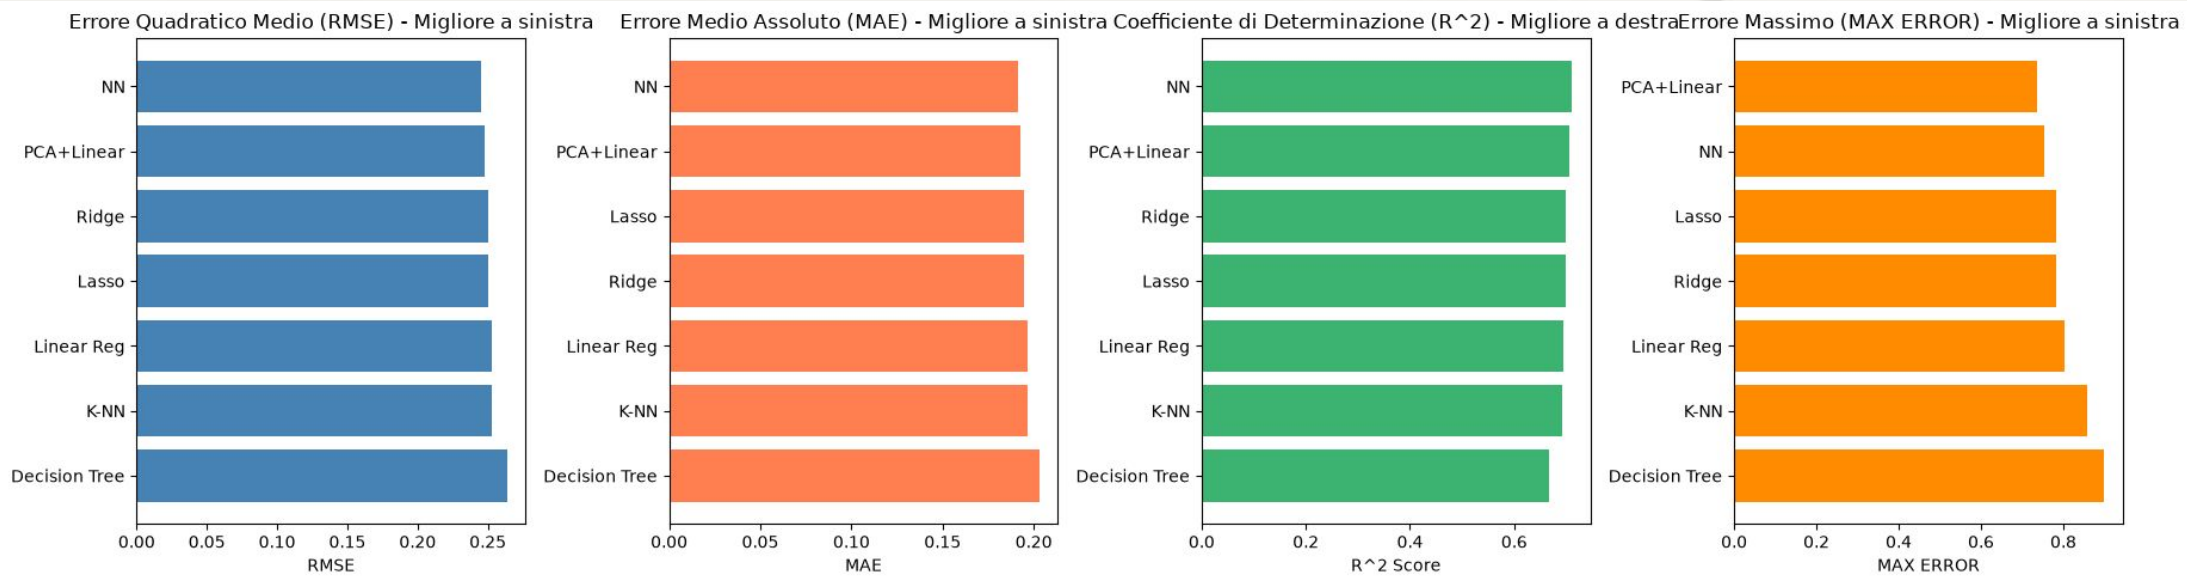
scarto_fh	<=1 C	1-2 C	>2 C
gruppo			
alto	14	0	2
basso	196	6	2
intermedio	34	1	0

-- Correlazione di Spearman con l'errore assoluto (tutto il test set) --
scarto_fh 0.115
gap_max 0.061
abs_err 1.000
Name: abs_err, dtype: float64

Mann-Whitney su scarto_fh (alto vs basso): p = 0.0321

Errori alti con sottostima (err > 0): 11
Errori alti con sovrastima (err < 0): 5

CONCLUSIONI



- **Risultato:** tutti i modelli stimano la temperatura orale con RMSE di circa 0,25 °C e bias trascurabile; le differenze tra modelli sono inferiori all'incertezza del test set.
- **Origine del miglioramento:** riconducibile quasi interamente alla calibrazione di T_Max1 (offset di 0,95 °C; una retta sul solo T_Max1 riduce l'RMSE a 0,26 °C). Le altre feature, comprese etnia ed età, aggiungono circa 0,01 °C. Lo stesso risultato è tuttavia raggiungibile con lo stesso dataset, escludendo il predittore T_Max1.
- **Modello scelto:** regressione regolarizzata (Ridge o Lasso). A parità di errore con la rete neurale è più semplice, stabile e leggibile.
- **Limiti:**
  - Le temperature elevate sono sottostimate, quindi per lo screening il cutoff va scelto sulla sensibilità desiderata.
  - L'errore iniziale è quasi interamente riconducibile a un offset sistematico (0,95 °C), eliminabile con una calibrazione. L'informazione predittiva utile è condivisa tra le temperature facciali: T_Max1 da solo dà un RMSE di 0,26, le altre feature senza T_Max1 danno 0,25-0,26. Le feature ambientali affinano la stima, con un effetto stabile della temperatura ambiente. Il margine di miglioramento è ridotto perché l'errore residuo è ormai prossimo all'incertezza dello strumento di riferimento (0,25 °C).