

INFRARED THERMOGRAPHY

Studio di un dataset di termografia con termometri IR e
correzione dei valori registrati attraverso modelli di ML



AGENDA

1. INTRODUZIONE e IDEA
2. DESCRIZIONE DEL DATASET
3. EDA
4. MODELLI
5. CONCLUSIONI



1. INTRODUZIONE E IDEA

La **pandemia** ha portato alla diffusione dei sensori per la misura della temperatura a infrarossi (**IRT**). Essi permettono a differenza dei termometri classici uno screening di massa molto veloce.

Tuttavia impreciso!

L'IDEA: sviluppare e confrontare dei modelli di ML che possano **correggere gli errori di misurazione**, avendo come riferimento la temperatura misurata con termometro classico in sito orale.



1. INTRODUZIONE E IDEA

La misura della temperatura spesso ha:

- un **sito di misura** (dove il termometro effettua la misura)
- un **sito di riferimento** (sito di cui si stima la temperatura, la temperatura in output fornita dal sensore è riferita a questo sito).

Nella “non-contact infrared thermometer” (NCIT) è spesso misurata la temperatura della pelle, che viene riferita alla temperatura della cavità orale (come nel dataset usato) .

Questa “conversione” dalla misura al sito di riferimento può risultare **non accurata** per molteplici **fattori**:

- meccanismo di termoregolazione del corpo umano estremamente complesso,
- colore ed etnia del soggetto
- condizioni della pelle
- fattori ambientali



2. DATASET

PAPER:

“Infrared Thermography for Measuring
Elevated Body
Temperature: Clinical Accuracy,
Calibration, and Evaluation”

STRUMENTAZIONE:

1. TERMOMETRO ORALE
2. TERMOMETRO IR
3. WEBCAM
4. BLACKBODY



PROCEDURA:

Prima della misura i soggetti sono stati:

1. fatti acclimatare nell'ambiente condizionato per almeno 15 minuti;
2. posti a una distanza compresa tra 0.6 m e 0.8 m dal sistema webcam-IRT.

È stata, quindi, misurata la temperatura sia con il sistema IRT che con il termometro orale

2. DATASET - FEATURES

PAZIENTE

1. **Age** (in fasce discretizzate)
2. **Gender**
3. **Ethnicity**
4. Le temperature, tutte registrate in gradi celsius, sono così divise:




Figure 1. Delineated facial regions and critical points on thermal images: forehead regions and points (green), canthi region and points (red), mouth region (gray rectangle), and entire face (blue rectangle).

Note: The above image is a generic face (based on PowerPoint clip art: Insert > Icons > Cutout People > Alfredo) used for illustration purposes and not an actual participant in our study.

2. DATASET - FEATURES

AMBIENTALI

1. **T_offset1**: offset tra temperatura registrata del blackbody e temperatura reale
2. **T_atm**: temperatura dell'ambiente in cui è stata effettuata la misura
3. **Humidity**: percentuale di umidità dell'ambiente in cui è stata effettuata la misura
4. **Distance**: distanza tra soggetto e IRT



2. DATASET

LABEL

Nell'esperimento la temperatura orale è stata registrata in modalità "fast" e "medium" a seconda del tempo più o meno lungo della misura stessa.

È stato scelto come temperatura target il valore misurato con esposizione più lunga perché più accurato.



	aveOralF	aveOralM
count	1020.000000	1020.000000
mean	36.979216	37.028382
std	0.386403	0.509502
min	35.750000	35.540000
25%	36.800000	36.777500
50%	36.900000	36.940000
75%	37.100000	37.140000
max	39.600000	40.340000

3. EDA

- FILTRAGGIO DEI SAMPLE CON FEATURE CON DATI MANCANTI → ELIMINATE
- CONTROLLO DEI VALORI SPERIMENTALI CON min e max →

Distance aveva samples inconsistenti:
ELIMINATI I SAMPLE NON APPARTENENTI ALL'INTERVALLO [0.5;0.9]

Si è scelto un intervallo più leggermente più largo, rispetto a quello dichiarato nel paper, perché dovuti all'errato posizionamento del soggetto e non all'errata misura della distanza.

- È STATO CREATO IL DATASET ANDANDO A GESTIRE LE FEATURE CATEGORICHE

Distance	
count	1018.000000
mean	0.729784
std	2.456486
min	0.540000
25%	0.600000
50%	0.620000
75%	0.700000
max	79.000000




Distance	
count	1015.000000
mean	0.652315
std	0.066794
min	0.540000
25%	0.600000
50%	0.620000
75%	0.700000
max	0.850000

```
<class 'pandas.DataFrame'>
RangeIndex: 1015 entries, 0 to 1014
Data columns (total 37 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Fascia_Eta                            1015 non-null   float64
1   Asian                                1015 non-null   float64
2   Black/African_American                1015 non-null   float64
3   Hispanic/Latino                       1015 non-null   float64
4   Multiracial                           1015 non-null   float64
5   White                                 1015 non-null   float64
6   T_atm                                 1015 non-null   float64
7   Humidity                              1015 non-null   float64
8   Distance                              1015 non-null   float64
9   T_offset1                             1015 non-null   float64
10  Max1R13_1                             1015 non-null   float64
11  Max1L13_1                             1015 non-null   float64
12  aveAllR13_1                           1015 non-null   float64
13  aveAllL13_1                           1015 non-null   float64
14  T_RC1                                  1015 non-null   float64
15  T_RC_Dry1                             1015 non-null   float64
16  T_RC_Wet1                             1015 non-null   float64
17  T_RC_Max1                             1015 non-null   float64
18  T_LC1                                  1015 non-null   float64
19  T_LC_Dry1                             1015 non-null   float64
...
35  T_OR_Max1                             1015 non-null   float64
36  ave0raIM                              1015 non-null   float64
dtypes: float64(37)
memory usage: 293.5 KB
```

3. EDA




- VISUALIZZAZIONE POPOLAZIONE (divisa in bin) CON ISTOGRAMMI → SBILANCIAMENTO CLASSI ❌



3. EDA

- VISUALIZZAZIONE POPOLAZIONE (divisa in bin) CON ISTOGRAMMI →

HP DI
GAUSSIANITÀ



3. EDA

→ MATRICE DI CORRELAZIONE E SELEZIONE FEATURE:

Le feature relative alla misurazione della temperatura sono tra loro molto correlate essendo relative allo stesso individuo.

La correlazione tra feature può rendere i modelli, soprattutto di regressione, instabili e complicare la computazione.


Sono state mantenute solo le feature che registrano la media dei 4 pixel con temperatura più elevata in quel distretto, seguendo due motivazioni:

- ◆ la media su una popolazione abbassa la deviazione standard con la radice del numero dei campioni che compongono la media (in questo caso $\text{std}/2$);
- ◆ le temperature massime, nelle varie zone facciali, sono quelle che presentano una maggiore correlazione con la label.


→ Dopo aver selezionato le feature, sono stati prodotti i sottoinsiemi di train e test.

Le feature sono state poi **standardizzate** (solo feature continue) non includendo le label nella standardizzazione stessa (come prassi, sarebbe leakage).





Data Engineering: La Pipeline di Preprocessing



Nota metodologica: I target (label y) non sono stati standardizzati.

4. MODELLI

1. K-NN

2. DECISION TREE

3. REGRESSORE LINEARE

a. SEMPLICE

b. RIDGE



c. LASSO

4. NN

5. REGRESSORE LINEARE CON
PCA




4.1 MODELLI: K-NN (K = 13)





Non performa bene nelle code in cui ci sono pochi sample. Nella parte a maggiore densità di campioni riesce a modellare bene il fenomeno.

4.2 MODELLI: DECISION TREE (d = 3)




Decision Tree Regressor (best model)



Pur garantendo buone performance sull'errore, gli alberi decisionali non generano una funzione di regressione continua, restituiscono infatti una stima a tratti costante, modellata attraverso una serie di iperpiani ortogonali agli assi. Inoltre, i punti nelle code della retta non sono così significativi da introdurre altri "batch".



4.3.a MODELLI: LINEAR REGRESSION



IL MODELLO DI REGRESSIONE
E' IL PIÙ PROMETTENTE TRA
QUELLI VISTI FINO AD ORA.
LAVORIAMO SU ESSO PER
MIGLIORARE LE PERFORMANCE
DI ERRORE: PROVIAMO A
REGOLARIZZARE IL MODELLO
PER RENDERLO PIÙ STABILE
NELLE PREVISIONI.



4.3.b MODELLI: RIDGE




RIDGE DS COMPLETO

Alpha scelto da RidgeCV: 10.0



```
Coefficienti: [ 0.01273843 -0.03946225  0.03324977  0.06036029 -0.04314994 -0.00676061
-0.02845223 -0.08822291  0.00916647  0.00850339  0.03092116  0.05488793
 0.03120763  0.04163564 -0.07143421 -0.00200657 -0.07875398  0.02607315
 0.00529297  0.0690581  0.07289747  0.26757903  0.06384628]
```

Intercetta: 37.033129596604276

4.3.b MODELLI: RIDGE



4.3.c MODELLI: LASSO




Lasso Model DS COMPLETO

Alpha scelto da LassoCV: 0.001

Coefficienti: [0.01133692 -0.0330808 0.03957345 0.06632875 -0.02521066 0.
-0.0139503 -0.08634769 0.00872492 0.00657285 0.03211086 0.05789055
0.0341315 0. -0.06606295 0. -0.07574185 0.02097969
0.00322991 0.05940169 0.07706716 0.32740581 0.03743358]

Intercetta: 37.0204062396498

4.3.c MODELLI: LASSO



4.3.b\c: OSSERVAZIONI SUI MODELLI REGOLARIZZATI

Ridge e Lasso riducono la varianza dei coefficienti e migliorano la stabilità predittiva mantenendo un'elevata spiegabilità clinica. Si possono notare nei coefficienti ridisegnati delle similitudini significative in alcuni predittori.

Fascia_Eta, genere, T_atm, Humidity, Distance e T_offset1 hanno praticamente lo stesso coefficiente nei tre modelli: sono poco correlate con le altre feature e il loro effetto è ben identificato.

T_Max1 è in ogni caso il predittore dominante.


I cinque coefficienti delle dummy di etnia scendono tutti di una quantità quasi uguale, mentre le loro differenze reciproche restano simili. Poiché le dummy sommano quasi a una costante, il loro livello comune è collineare con l'intercetta. **Sono quindi interpretabili solo le differenze tra gruppi, non i valori assoluti.**

Sulle temperature facciali, fortemente correlate tra loro, i due metodi si comportano in modo diverso.

LASSO, per la geometria della penalità L1, produce zeri esatti, Ridge non azzera nulla, ma riduce T_Max1 (da circa 0,33 a 0,27) e ne ridistribuisce il peso sulle feature correlate.


4.4 MODELLI: NN

Proviamo un altro
approccio rispetto a
quello lineare




4.4 MODELLI: NN

Miglior modello per
accuratezza
globale (RMSE) e
varianza spiegata.



MODELLI: LINEAR REGRESSION+PCA

Tentativo
sperimentale. PCA su
dataset per via
dell'alta correlazione.



Linear Regression con PCA

Numero di componenti principali usate: 12

Coefficienti (sulle componenti PCA): [0.12080748 -0.17736512 0.04065503 0.00937813 0.02398772 0.0483063
0.0545959 -0.14787765 0.02544074 0.06548973 -0.03832294 0.01772476]

RISULTATI

- Lo studio di riferimento (Wang et al., 2022) considera clinicamente affidabile un sistema IRT che mantenga una deviazione standard dell'errore inferiore a 0.3 °C.
 - Gli RMSE ottenuti (0.25), con bias praticamente nulli, equivalgono alla deviazione standard soddisfano il limite.
 - Il MAE, più basso (≈ 0.19), indica che l'errore sul paziente tipico è ben inferiore ed è concentrato in poche istanze estreme.

```
_____ DATASET DI PARTENZA _____  
Test RMSE (D): 0.9856  
Test MAE (D): 0.9480  
Test R^2 (D): -3.6627  
MAX ERROR (D): 1.7575  
Test bias (D): 0.9480
```




```
===== CONFRONTO PERFORMANCE MODELLI =====  
Modello    RMSE    MAE    R^2    MAX ERROR  
K-NN 0.253078 0.196717 0.692595 0.858617  
Decision Tree 0.263647 0.203137 0.666382 0.900000  
Linear Reg 0.252810 0.196377 0.693245 0.801726  
Ridge 0.250088 0.194766 0.699815 0.782567  
Lasso 0.250462 0.194428 0.698918 0.782175  
PCA+Linear 0.247324 0.192782 0.706413 0.735094  
NN 0.245427 0.191174 0.710900 0.752258  
=====
```

- Una interessante conclusione dello studio è il fatto che le feature relative all'etnia e all'età del soggetto hanno una importanza marginale nella misura rispetto a quella prevista.
- Andrebbe, tuttavia, mitigato il **problema dell'errore massimo.**




RISULTATI


Errore Quadratico Medio (RMSE) - Migliore a sinistra




Errore Medio Assoluto (MAE) - Migliore a sinistra



Coefficiente di Determinazione (R^2) - Migliore a destra



Errore Massimo (MAX ERROR) - Migliore a sinistra



I modelli migliori per una adozione in ambito sanitario si sono rivelati i **regressori lineari regolarizzati con lasso e ridge**. Essi infatti riescono a mantenere delle prestazioni molto simili alla NN (di poco inferiori) e hanno il grande pregio di essere estremamente interpretabili.



RISULTATI - FAIRNESS/ERRORE MAX

Per completare lo studio si è scelto di eseguire una **analisi di fairness** per ognuno dei modelli, in quanto consapevolmente non era stato affrontato il problema dello squilibrio delle classi, avendo ottenuto dati comunque promettenti.

Come anticipato, in alcune categorie, l'analisi statistica non è rilevante per il numero di campioni.


Riguardo all'errore massimo si sono sviluppate 4 ipotesi:

1. Le feature non contengono tutta l'informazione necessaria alla predizione.
2. I sample che sono classificati in maniera errata sono rumorosi.
3. Problema di fairness e sottorappresentazione.




RISULTATI

Analisi errore per categoria - Ridge




Analisi errore per categoria - Lasso



RISULTATI

Analisi errore per categoria - NN



RISULTATI

L'analisi di fairness non ha evidenziato dei comportamenti squilibrati tra classi: media dell'errore sempre simile e range degli errori nella popolazione distribuiti ugualmente. L'unica classe in cui i valori non sono uniformi è quella relativa all'età.

Tuttavia, si può notare che nelle classi con **piu campioni vi è un errore maggiore**, pertanto, si è escluso che l'errore dipenda dalle classi sottorappresentate.


Nelle previsioni si può notare anche un fenomeno di **regressione verso la media**: nello scatter i valori nelle code sono sottostimati (per temperature >38), sovrastimati (per temperature <36.5). Il modello, minimizzando l'errore quadratico, tira le previsioni verso il centro, dove sta la maggior parte dei dati. Questo, tuttavia, **non risulta essere un problema serio nelle previsioni**.



CONCLUSIONE

Gli errori superiori a 0.5 °C non sono riconducibili a errori di misura (discordanze evidenti tra le misure orali di riferimento (un caso su 16)), né, salvo due casi, ad anomalie nelle acquisizioni della fronte da parte dell'apparato IRT. L'errore residuo è compatibile con la combinazione di rumore di misura del target (circa 0.2 °C di dispersione tra le due misure orali), variabilità fisiologica non catturata dalle feature disponibili e tendenza del modello a sottostimare le temperature elevate, poco rappresentate nel training.

I dati non consentono di separare il contributo dell'errore strumentale della termocamera da quello delle variabili non osservate.



Label aveOralM fuori da [35.0, 40.5] C: 0

aveOralF	aveOralM	diff	abs_diff
----------	----------	------	----------

Soglia di discordanza: 0.667 C dallo scostamento mediano (-0.040 C)

Label sospette: 26 su 1020

aveOralF	aveOralM	diff	abs_diff	sospetta	
751	37.15	38.49	-1.34	1.34	True
495	37.45	38.69	-1.24	1.24	True
358	37.30	38.44	-1.14	1.14	True
78	37.45	38.54	-1.09	1.09	True
132	37.35	38.39	-1.04	1.04	True
72	37.65	38.69	-1.04	1.04	True
874	37.90	38.94	-1.04	1.04	True
129	38.95	37.99	-1.04	1.04	True
292	37.35	38.29	-0.94	0.94	True
774	36.85	37.74	-0.89	0.89	True
721	37.00	37.89	-0.89	0.89	True
686	37.40	38.29	-0.89	0.89	True
314	36.90	37.74	-0.84	0.84	True
836	37.35	38.19	-0.84	0.84	True
839	38.30	39.09	-0.79	0.79	True
93	37.00	37.79	-0.79	0.79	True
791	37.15	37.94	-0.79	0.79	True
112	36.40	35.64	0.76	0.76	True
823	36.85	37.59	-0.74	0.74	True
212	36.90	37.64	-0.74	0.74	True
122	39.60	40.34	-0.74	0.74	True
150	37.25	37.99	-0.74	0.74	True
747	37.00	37.74	-0.74	0.74	True
128	36.70	37.44	-0.74	0.74	True
837	37.20	37.94	-0.74	0.74	True
320	36.70	35.99	0.71	0.71	True

```
-- Punti con errore > 0.5 --
T_FHCC1 T_FHRC1 T_FHLC1 T_FHBC1 T_FHTC1 T_FH_Max1 scarto_fh gap_max y_true y_pred err abs_err
741 34.542 35.275 34.588 34.735 34.878 36.815 0.733 1.473 37.14 37.922 -0.782 0.782
887 34.980 34.448 35.178 35.028 33.108 35.700 2.070 2.593 37.89 37.146 0.742 0.742
924 32.710 34.448 32.252 33.518 31.962 35.902 2.465 3.940 37.24 37.966 -0.726 0.726
514 34.215 34.138 34.400 34.122 33.828 35.870 0.572 1.242 36.74 37.364 -0.624 0.624
722 34.408 34.655 34.728 34.380 34.245 35.162 0.483 0.918 37.89 37.285 0.605 0.605
854 33.483 33.707 34.057 33.067 33.627 34.453 0.990 1.387 36.74 36.137 0.603 0.603
464 33.840 33.822 34.222 33.680 34.122 35.095 0.542 1.415 37.09 36.488 0.602 0.602
664 35.508 35.562 35.778 35.582 35.642 36.175 0.275 0.672 37.04 37.638 -0.598 0.598
751 35.738 35.842 35.852 35.842 35.782 36.148 0.150 0.445 38.49 37.894 0.596 0.596
754 34.758 34.765 34.800 34.945 34.478 36.268 0.468 1.790 38.54 37.979 0.561 0.561
344 34.470 34.392 34.382 34.522 34.800 35.162 0.417 0.780 37.59 37.046 0.544 0.544
411 34.218 34.170 34.118 34.035 33.770 34.712 0.447 0.942 37.34 36.801 0.539 0.539
1018 34.840 35.020 34.925 34.715 34.595 35.415 0.425 0.820 37.29 36.768 0.522 0.522
685 34.465 34.852 34.555 34.380 34.750 35.512 0.472 1.133 37.39 36.871 0.519 0.519
998 36.168 36.085 36.130 36.168 35.215 36.935 0.952 1.720 38.74 38.228 0.512 0.512
519 34.668 34.892 34.452 34.432 34.865 36.125 0.460 1.693 36.89 37.392 -0.502 0.502
```

```
-- Statistiche degli indicatori per gruppo --
scarto_fh gap_max
count median mean max count median mean max
gruppo
alto 16 0.477 0.746 2.485 16 1.315 1.435 3.940
basso 204 0.405 0.472 2.350 204 1.013 1.079 2.718
intermedio 35 0.360 0.452 1.788 35 1.125 1.122 2.575

-- Numero di punti per gruppo e fascia di scarto della fronte --
scarto_fh <=1 C 1-2 C >2 C
gruppo
alto 14 0 2
basso 196 6 2
intermedio 34 1 0

-- Correlazione di Spearman con l'errore assoluto (tutto il test set) --
scarto_fh 0.115
gap_max 0.061
abs_err 1.000
Name: abs_err, dtype: float64

Mann-Whitney su scarto_fh (alto vs basso): p = 0.0321

Errori alti con sottostima (err > 0): 11
Errori alti con sovrastima (err < 0): 5
```